PERAMALAN HARGA DAN PRODUKSI CABAI MERAH DI PROVINSI LAMPUNG MENGGUNAKAN LONG SHORT-TERM MEMORY

TUGAS AKHIR

Khoirunnisa
120450029



PROGRAM STUDI SAINS DATA
FAKULTAS SAINS
INSTITUT TEKNOLOGI SUMATERA
2025

PERAMALAN HARGA DAN PRODUKSI CABAI MERAH DI PROVINSI LAMPUNG MENGGUNAKAN LONG SHORT-TERM MEMORY

TUGAS AKHIR

Diajukan sebagai syarat untuk memperoleh gelar Sarjana

Khoirunnisa
120450029



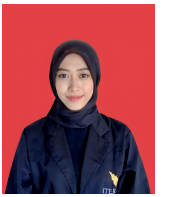
PROGRAM STUDI SAINS DATA
FAKULTAS SAINS
INSTITUT TEKNOLOGI SUMATERA
2025

HALAMAN PENGESAHAN

Tugas Akhir Sarjana dengan judul "**Peramalan Harga dan Produksi Cabai Merah di Provinsi Lampung Menggunakan Long Short-Term Memory**" adalah benar dibuat oleh saya sendiri dan belum pernah dibuat dan diserahkan sebelumnya, baik sebagian ataupun seluruhnya, baik oleh saya ataupun orang lain, baik di Institut Teknologi Sumatera maupun di institusi pendidikan lainnya.

Lampung Selatan, 25 Juli 2025

Penulis,



Khoirunnisa
NIM. 120450029

Diperiksa dan disetujui oleh,

Pembimbing I	Pembimbing II
Sri Karnila, S.Kom., M.Kom.	**Mika Alvionita S, M.Si.**
NIP. 119920212202203201 3	**NRK. 1993050920212258**

Disahkan oleh,
Koordinator Program Studi Sains Data
Fakultas Sains
Institut Teknologi Sumatera

Tirta Setiawan, S.Pd., M.Si.
NIP. 199008222022031003

Sidang Tugas Akhir:

Penguji I : Luluk Muthoharoh, M.Si.
Penguji II : Tirta Setiawan, S.Pd., M.Si.

HALAMAN PERNYATAAN ORISINALITAS

Skripsi ini adalah karya saya sendiri dan semua sumber baik yang dikutip maupun yang dirujuk telah saya nyatakan benar.

Nama	:	**Khoirunnisa**
NIM	:	**120450029**
Tanda tangan	:	
Tanggal	:	**25 Juli 2025**

HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI UNTUK KEPENTINGAN AKADEMIS

Sebagai civitas akademik Institut Teknologi Sumatera, saya yang bertanda tangan di bawah ini:

Nama	:	Khoirunnisa
NIM	:	120450029
Program Studi	:	Sains Data
Fakultas	:	Sains
Jenis karya	:	Tugas Akhir

demi pengembangan ilmu pengetahuan, menyetujui untuk memberikan Hak Bebas Royalti Noneksklusif (*Non-Exclusive Royalty Free Right*) kepada Institut Teknologi Sumatera atas karya ilmiah saya yang berjudul:

Peramalan Harga dan Produksi Cabai Merah di Provinsi Lampung Menggunakan Long Short-Term Memory

beserta perangkat yang ada (jika diperlukan). Dengan Hak Bebas Royalti Noneksklusif ini Institut Teknologi Sumatera berhak menyimpan, mengalihmedia/format-kan, mengelola dalam bentuk pangkalan data (*database*), merawat, dan memublikasikan tugas akhir saya selama tetap mencantumkan nama saya sebagai penulis/pencipta dan sebagai pemilik Hak Cipta.

Demikian pernyataan ini saya buat dengan sebenarnya.

Dibuat di	:	Lampung Selatan
Pada tanggal	:	25 Juli 2025

Yang menyatakan

Khoirunnisa

ABSTRAK

Peramalan Harga dan Produksi Cabai Merah di Provinsi Lampung Menggunakan Long Short-Term Memory

Khoirunnisa (120450029)
Pembimbing I: Sri Karnila, S.Kom., M.Kom.
Pembimbing II: Mika Alvionita S, M.Si.

Fluktuasi harga cabai merah yang signifikan di Provinsi Lampung dapat memicu inflasi dan mengganggu kestabilan ekonomi masyarakat. Penelitian ini bertujuan untuk meramalkan harga dan produksi cabai merah menggunakan metode *Long Short-Term Memory* (LSTM). Data yang digunakan meliputi harga dan jumlah produksi cabai merah dari Januari 2019 hingga Desember 2023. Data dianalisis dalam bentuk deret waktu dan diproses melalui tahapan normalisasi, pembagian data latih dan uji, serta pelatihan model dengan kombinasi *hyperparameter*. Hasil pengujian menunjukkan bahwa model LSTM dengan 2 *hidden layer*, 32 *neuron*, *batch size* 1, panjang *sequence* 6, dan 500 *epoch* memberikan performa terbaik dengan nilai MAE sebesar 625,46 untuk harga dan 327,67 untuk produksi, serta nilai MAPE sebesar 2,06% untuk harga dan 3,75% untuk produksi.

Kata kunci: LSTM, peramalan, harga cabai merah, produksi, Provinsi Lampung

ABSTRACT

Forecasting the Price and Production of Red Chili in Lampung Province Using Long Short-Term Memory

Khoirunnisa (120450029)
Advisor I: Sri Karnila, S.Kom., M.Kom.
Advisor II: Mika Alvionita S, M.Si.

The significant price fluctuations of red chili in Lampung Province can trigger inflation and disrupt economic stability. This study aims to forecast the price and production of red chili using the Long Short-Term Memory (LSTM) method. The data used includes monthly records of red chili prices and production from January 2019 to December 2023. The time-series data were processed through normalization, training-testing split, and model training with various hyperparameter configurations. The results show that the LSTM model with 2 hidden layers, 32 neurons, batch size of 1, sequence length of 6, and 500 epochs achieved the best performance, with a Mean Absolute Error (MAE) of 625.46 for price and 327.67 for production, and a Mean Absolute Percentage Error (MAPE) of 2.06% for price and 3.75% for production.

Keywords : *LSTM, forecasting, red chili price, production, Lampung Province*.

MOTTO

"... But perhaps you hate a thing and it is good for you; and perhaps you love a thing and it is bad for you. And Allah Knows, while you know not."
(2:216)

"Semua jatuh bangunmu hal yang biasa, angan dan pertanyaan waktu yang menjawabnya, berikan tenggat waktu bersedihlah secukupnya, rayakan perasaanmu sebagai manusia"
(Mata Air - Hindia)

HALAMAN PERSEMBAHAN

Sebuah hasil tulisan penulis, skripsi ini dipersembahkan untuk orang tua dan keluarga tercinta yang telah memberikan bimbingan secara moral, spiritual, dan juga materi. Sehingga penulis dapat senantiasa mengerjakan skripsi ini dengan semangat, dan bisa lulus dalam menggapai gelar sarjananya.

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Allah SWT atas berkah dan rahmat-Nya sehingga skripsi ini dapat terselesaikan dengan baik. Skripsi ini dibuat untuk menyelesaikan pendidikan jenjang sarjana pada Institut Teknologi Sumatera. Penyusunan skripsi ini banyak mendapat bantuan dan dukungan dari berbagai pihak sehingga dalam kesempatan ini, dengan penuh kerendahan hati, penulis mengucapkan terima kasih kepada:

1. Prof. Dr. I Nyoman Pugeg Aryantha selaku Rektor InstitutTeknologi Sumatera beserta jajarannya,
2. Dr. Ikah Ning P. Permanasari, M.Si. selaku Dekan Fakultas Sains Institut Teknologi Sumatera,
3. Bapak Tirta Setiawan, S.Pd. M.Si. selaku Koordinator Program Studi sekaligus penguji kedua,
4. Ibu Sri Karnila, S.Kom., M.Kom. Nama selaku dosen pembimbing pertama dan,
5. Ibu Mika ALvionita, M.Si. selaku dosen pembimbing kedua yang selalu memberikan bimbingan, arahan dan motivasi kepada penulis selama proses penyusunan skripsi ini,
6. Ibu Luluk Muthoharoh, M.Si. selaku dosen penguji pertama saya yang telah memberikan kritik dan saran yang membangun dalam penyempurnaan penulisan skripsi ini,
7. Seluruh dosen dan tenaga kependidikan Sains Data Institut Teknologi Sumatera yang telah memberikan banyak bantuan dan ilmu selama penulis menempuh pendidikan strata 1,
8. Kepada instansi Dinas Ketahanan Pangan, Tanaman Pangan dan Hortikultura Provinsi Lampung atas izin menggunakan data produksi cabai merah di Provinsi Lampung, yang telah dipercayakan kepada saya. Data ini sangat berharga dan

berkontribusi besar terhadap keberhasilan penelitian skripsi penulis,

9. Teman-teman seperjuangan di Program Studi Sains Data 2020, atas kebersamaan, dukungan, dan warna pada proses perkuliahan penulis. Kepada Empat Miliar (Sekawan), Budaya, LSTM Squad, Teman sejak SMP yang masih mendukung sampai detik akhir sidang akhir, serta pihak dan teman-teman yang tidak dapat penulis sebutkan satu persatu, yang telah membantu dalam penyelesaikan skripsi ini,
10. Terkahir paling istimewa, untuk kedua orang tuaku, Bapak [redacted] dan Ibu [redacted] dan kakak tercinta [redacted] yang telah memberikan doa, dukungan, motivasi dan materi yang tak terhingga. Penulis ucapkan terima kasih juga karena kesabaran tanpa memberikan tekanan, sehingga penulis dapat menyelesaikan skripsi ini dengan tenang dan sepenuh hati,
11. *Last but not least for myself*—-(Khoirunnisa), *thanks to choosing not to give up, for staying up late, for continuing to learn despite failures, the patience with the process, the lessons learned through struggles, and for believing that I could finish this journey*

Penulis menyadari bahwa penyusunan Skripsi ini jauh dari sempurna. Akhir kata penulis mohon maaf yang sebesar-besarnya apabila ada kekeliruan di dalam penulisan skripsi ini.

Lampung Selatan, 25 Juli 2025

Khoirunnisa

DAFTAR ISI

HALAMAN JUDUL . . . . . **i**

HALAMAN PENGESAHAN . . . . . **ii**

HALAMAN PERNYATAAN ORISINALITAS . . . . . **iii**

HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI **iv**

ABSTRAK . . . . . **v**

ABSTRACT . . . . . **vi**

MOTTO . . . . . **vii**

HALAMAN PERSEMBAHAN . . . . . **viii**

KATA PENGANTAR . . . . . **ix**

DAFTAR ISI . . . . . **xi**

DAFTAR GAMBAR . . . . . **xii**

DAFTAR TABEL . . . . . **xiii**

I PENDAHULUAN **1**

1.1 Latar Belakang 1

1.2 Rumusan Masalah 3

1.3 Tujuan Penelitian 3

II TINJAUAN PUSTAKA **4**

2.1 Penelitian Terdahulu 4

2.2 Normalisasi Data 5

2.3 *Long Short-Term Memory* 7

2.4 Evaluasi Model 12

III METODE PENELITIAN **15**

3.1 Data Penelitian 15

3.2 Tahapan Penelitian 15

IV HASIL DAN PEMBAHASAN 20
4.1 Dataset 20
4.2 Normalisasi Data 22
4.3 Pembagian Data 23
4.4 Pengujian Model LSTM 24
4.4.1 1 *Hidden Layer* LSTM 24
4.4.2 2 *Hidden Layer* LSTM 26
4.5 Analisis Hasil Prediksi Model Terbaik 29

V KESIMPULAN DAN SARAN 34
5.1 Kesimpulan 34
5.2 Saran 34

DAFTAR PUSTAKA 36

LAMPIRAN 41

A Perhitungan 42
A.1 Total Hasil Produksi dalam Satuan Provinsi 42
A.2 Normalisasi Data (2.2) 42
A.3 LSTM (2.3) 45
A.4 Perhitungan Manual Total Parameter Model LSTM . 51
A.5 Perhitungan Denormalisasi 53
A.6 Perhitungan MAE dan MAPE 55

B Tabel Evaluasi Model 59
B.1 1 *Hidden Layer* LSTM 59
B.2 2 *Hidden Layer* LSTM 61

C Gambar Evaluasi Model 63
C.1 Gambar *Loss Training* 1 *Hidden Layer* LSTM 63
C.2 Gambar *Loss Training* 2 *Hidden Layer* LSTM 66

DAFTAR GAMBAR

Gambar 2.1 Arsitektur LSTM 7
Gambar 2.2 Forget Gate 9
Gambar 2.3 Input Gate 10
Gambar 2.4 Cell State 11
Gambar 2.5 Output Gate 12

Gambar 3.1 Tahapan Penelitian 16

Gambar 4.1 Visualisasi Data Penelitian 21
Gambar 4.2 Visualisasi Boxplot 22
Gambar 4.3 Visualisasi Evaluasi MAE 1 *Hidden Layer* LSTM 24
Gambar 4.4 Visualisasi Evaluasi MAPE 1 *Hidden Layer* LSTM 25
Gambar 4.5 Visualisasi Evaluasi MAE 2 *Hidden Layer* LSTM 26
Gambar 4.6 Visualisasi Evaluasi MAPE 1 *Hidden Layer* LSTM 27
Gambar 4.7 Grafik Perbandingan Variabel Harga 32
Gambar 4.8 Grafik Perbandingan Variabel Produksi . . . 32
Gambar 4.9 Peramalan Selama 6 Bulan Kedepan 33

DAFTAR TABEL

Tabel 2.1 Penelitian Terdahulu 4
Tabel 2.2 Penerimaan nilai MAPE 14

Tabel 3.1 Atribut Data 15
Tabel 3.2 *Hyperparameter* 17

Tabel 4.1 Dataset Penelitian 20
Tabel 4.2 Dataset Sebelum Normalisasi 23
Tabel 4.3 Dataset Setelah Normalisasi 23
Tabel 4.4 Pembagian Data Latih dan Uji 24
Tabel 4.5 Data Harga dan Produksi 31

Tabel A.1 Data Produksi Kabupaten/Kota di Provinsi Lampung (2018–2023) 42
Tabel A.2 Dataset Setelah Normalisasi 43
Tabel A.3 Tabel Perbandingan Harga Aktual dan Prediksi 57
Tabel A.4 Tabel Perbandingan Produksi Aktual dan Prediksi 58

Tabel B.1 Hasil Evaluasi Data Latih 1 *Hidden Layer* LSTM 59
Tabel B.2 Hasil Evaluasi Data Uji 1 *Hidden Layer* LSTM 60
Tabel B.3 Hasil Evaluasi Data Latih 1 *Hidden Layer* LSTM 61
Tabel B.4 Hasil Evaluasi Data Uji 2 *Hidden Layer* LSTM 62

BAB I

PENDAHULUAN

1.1 Latar Belakang

Cabai merah *(Capsicum annuum L.)* merupakan salah satu jenis kategori tanaman holtikultura yang banyak dikonsumsi oleh masyarakat di Indonesia[1]. Konsumsi cabai merah hampir digunakan setiap hari untuk berbagai keperluan, seperti sebagai bahan sayuran, penyedap masakan, dan pewarna makanan [2]. Menurut data dari Statistik Konsumsi Pangan, konsumsi cabai merah per kapita di Indonesia pada tahun 2023 sebesar 2,02 kg/kapita/tahun, meningkat dari tahun sebelumnya yaitu sebesar 1,9 kg/kapita/tahun [3]. Namun, cabai merah merupakan salah satu komoditas yang mengalami perubahan harga yang fluktuatif [4]. Fluktuasi harga disebabkan lonjakan harga yang dipicu oleh pasokan stok cabai yang tidak mencukupi akibat permintaan pasar yang tinggi, terutama pada momentum tertentu seperti hari raya dan hari besar lainnya. [5].

Harga komoditas cabai merah yang berfluktuatif dapat menyebabkan terjadinya inflasi pada daerah atau wilayah tertentu [6]. Inflasi akan berdampak besar dan merugikan terhadap pertumbuhan ekonomi, sehingga menyebabkan penurunan daya beli konsumen akibat kenaikan harga pangan [7]. Berdasarkan data dari Badan Pusat Statistik (BPS) Lampung, Provinsi Lampung mencatat inflasi tertinggi pada triwulan III tahun 2022 sebesar 7,04% *Years on Years* (YoY) dengan komoditas utama yang memicu inflasi adalah cabai merah [8]. Peramalan harga dan produksi cabai merah diperlukan untuk mengantisipasi inflasi yang dapat merugikan petani dan konsumen. Dengan demikian, dibutuhkan metode yang

dapat meramalkan harga dan produksi cabai merah di masa mendatang. [9].

Peramalan (*forecasting*) merupakan memperkirakan informasi di masa depan berdasarkan data masa lalu dan saat ini untuk membantu pengambilan keputusan dan perencanaan untuk mengantisipasi kondisi yang akan terjadi [10]. Salah satu metode yang dapat digunakan dalam peramalan data deret waktu adalah *Long Short-Term Memory* (LSTM). LSTM mengatasi ketergantungan jangka panjang pada inputnya dan dapat digunakan dalam berbagai tugas sekuensial. Data sekuensial memiliki karakteristik di mana suatu sampel dianalisis berdasarkan waktu dan sampel tersebut memiliki hubungan dengan sampel lainnya. Salah satu keunggulan utama LSTM terletak pada mekanisme sel memorinya yang mampu menentukan relevansi informasi input. Mekanisme sel memori berfungsi sebagai unit penyimpanan jangka panjang, sehingga LSTM dapat menangkap dependensi jangka panjang dalam data sekuensial [11].

Beberapa penelitian terkait peramalan harga komoditas cabai menggunakan metode *Long-Short Term Memory* dengan menggunakan bentuk data deret waktu harian telah dilakukan di beberapa daerah seperti Malang [7], Yogyakarta [9], dan Jawa Barat [5], dengan nilai evaluasi model berturut-turut sebesar 0,0155 (MSE), 3,6995% (MAPE), dan 4,09% (MAPE). Oleh karena itu, penelitian ini akan melakukan peramalan harga cabai merah menggunakan LSTM dengan memanfaatkan data terbaru dari wilayah Lampung serta memasukkan faktor tambahan yang relevan yaitu jumlah produksi cabai merah untuk memberikan kontribusi nyata dalam mengatasi masalah fluktuasi harga cabai merah yang berdampak luas pada ekonomi dan kesejahteraan masyarakat. Dengan demikian, penelitian ini diharapkan dapat lebih efektif

dalam mengantisipasi fluktuasi harga, menjaga stabilitas pasar, dan mengendalikan inflasi [7].

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan sebelumnya, rumusan masalah pada penelitian ini adalah bagaimana penerapan dan hasil peramalan harga cabai merah di Provinsi Lampung menggunakan metode *Long-Short Term Memory* (LSTM).

1.3 Tujuan Penelitian

Tujuan dari penelitian ini berdasarkan rumusan masalah yang juga menjadi dasar dilakukannya penelitian ini adalah menerapkan dan mengevaluasi hasil peramalan harga cabai merah di Provinsi Lampung menggunakan metode *Long-Short Term Memory* (LSTM).

BAB II

TINJAUAN PUSTAKA

2.1 Penelitian Terdahulu

Pada Subbab ini menyertakan beberapa penelitian sebelumnya yang relevan dengan topik yang dibahas dalam penelitian ini. Hal ini digunakan sebagai referensi untuk perbandingan serta sebagai panduan dalam memahami dalam metode yang diterapkan. Berikut adalah tabel ringkasan dari penelitian sebelumnya ditampilkan dalam Tabel 2.1.

Tabel 2.1 Penelitian Terdahulu

No	Tahun	Penulis	Judul	Hasil Penelitian
1	2024	Arieska Restu, Donny Avianto	Implementasi Algoritma LSTM Untuk Prediksi Harga Cabai Merah Keriting di Yogyakarta	Akurasi terbaik diperolah ketika menggunakan pembagian data dengan perbandingan 70%:30%, ukuran *batch* 48, nilai *learning rate* 0,001, jumlah *neuron* 30, dengan optimasi Adam dan aktivasi ReLU, yang menghasilkan nilai evaluasi MAPE 3,6995%.
2	2023	Amalda Puspa, Yuyun Hidayat, Defi Yusti	Peramalan Harga Aneka Cabai Menggunakan Metode *Long Short Term Memory* (LSTM) Studi Kasus di Provinsi Jawa Barat	Hasil pengujian akurasi terbaik didapat dengan menggunakan 2 *layer*, 110 *neuron*, 32 *batch size* dan optimizer adam didapatkan nilai MAPE 4,09% untuk cabai merah. Dengan menggunakan 2 *layer* dengan 100 *neuron*, 32 *batch size*, dan optimizer Adam, nilai MAPE untuk cabai rawit merah adalah 4,90%.

No	Tahun	Penulis	Judul	Hasil Penelitian
3	2023	Michael David, Imam Cholissodin, Novanto Yudistira	Prediksi Harga Cabai menggunakan Metode *Long-Short Term Memory* (Case Study : Kota Malang)	Hasil pengujian akurasi terbaik didapat dengan mpembagian data dengan perbandingan 70%;30%, panjang *sequence* 21, *hidden unit* 128 dan epoch 150 dengan nilai MSE 0,0155.
4	2023	Rahmad Firdaus, Harun Mukhtar, Awaluddin	Prediksi Indeks Harga Produsen Pertanian Karet Di Indonesia Menggunakan Metode LSTM	Percobaan ini menghasilkan akurasi terbaik dengan 50 *neuron*, 25 *epoch*, dan 10 *stack size* dengan nilai RMSE data latih 384,20 dan nilai RMSE data uji sebesar 306,01 dan nilai latih MAPE sebesar 1,25% dan nilai uji MAPE sebesar 1,09%.
5	2020	Bagas Aji Aprian, Yufis Azhar, Vinna Rahmayanti	Prediksi Pendapatan Kargo Menggunakan Arsitektur *Long Short Term Memory*	Penelitian ini menghasilkan model terbaik dengan menggunakan komposisi data latih 90% dan data uji 10%, dengan jumlah *neuron* 128 dan 900 *epoch* dengan nilai evaluasi RMSE pada data latih 641375,70 dan data uji 594197,70.

2.2 Normalisasi Data

Normalisasi merupakan tahap praproses data sebelum data diolah dalam pemodelan. Normalisasi bertujuan untuk meningkatkan kecepatan pelatihan LSTM pada proses pembelajaran model [12]. Salah satu teknik normalisasi yang digunakan adalah menggunakan *MinMax Scaler* yang mengubah rentang nilai data menjadi antara [0,1][13]. Proses normalisasi data melibatkan pengubahan nilai data untuk menciptakan interval nilai yang sesuai untuk model peramalan. Normalisasi data dapat dilakukan dengan bantuan

modul *MinMax Scaler* dari *library scikit-learn*, yang akan menghasilkan data dengan nilai interval [0,1]. Normalisasi data juga dilakukan untuk memastikan nilai *input* memiliki interval yang selaras dengan sifat fungsi sigmoid yang menghasilkan *output* pada interval [0,1] [14]. Persamaan dari normalisasi data menggunakan *MinMax Scaler* dilihat dalam Persamaan 2.1:

$$X' = \frac{X - X_{\min}}{X_{\max} - X_{\min}} \tag{2.1}$$

Keterangan:

X' : nilai setelah dinormalisasi
X : nilai asli sebelum dinormalisasi
$X_{\max}$: nilai maksimum dalam data
$X_{\min}$: nilai minimum dalam data

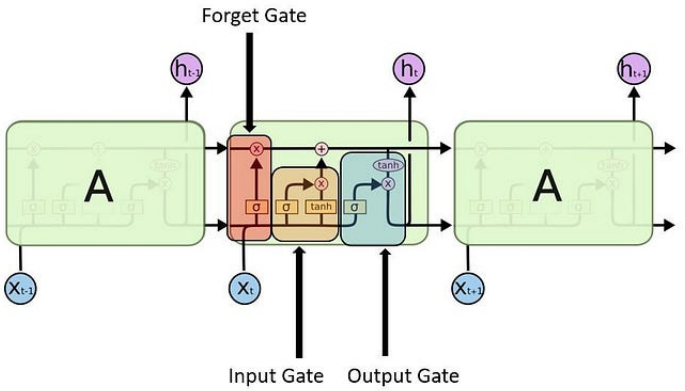
Setelah proses prediksi selesai, normalisasi data aktual dan hasil prediksi harus dikembalikan ke skala aslinya. Proses ini dilakukan dengan menggunakan Persamaan 2.2 yang berfungsi mengonversi kembali nilai yang telah dinormalisasi kembali ke bentuk asli. Untuk memudahkan analisis dan pengambilan keputusan, langkah ini penting agar hasil peramalan dapat diinterpretasikan dalam konteks yang sesuai dengan skala data asli [15].

$$X = X' \cdot (X_{\max} - X_{\min}) + X_{\min} \tag{2.2}$$

Keterangan :

X' : nilai setelah dinormalisasi
X : nilai asli sebelum dinormalisasi
$X_{\max}$: nilai maksimum dalam data
$X_{\min}$: nilai minimum dalam data

2.3 *Long Short-Term Memory*



Gambar 2.1 Arsitektur LSTM[16].

Hochreiter dan Schmidhuber (1997) memperkenalkan model *Long Short-Term Memory* (LSTM). Jaringan LSTM terdiri dari unit gerbang *(gate units)* dan sel memori *(memory cell)*. Dengan menambahkan sel memori yang dapat menyimpan informasi untuk jangka waktu yang lama, LSTM dapat digunakan sebagai metode untuk memprediksi mengenai data deret waktu dalam jangka waktu tertentu [17].

LSTM memiliki beberapa komponen utama, yaitu *forget gate*, *input gate*, *cell state*, *output gate*. Di dalam LSTM, digunakan dua jenis fungsi aktivasi yaitu sigmoid dan tanh. Fungsi sigmoid (σ) digunakan pada *forget gate*, *input gate* dan *output gate* dan nilai keluaran berada di interval nol hingga satu 0 hingga 1 [0,1]. Fungsi tanh digunakan pada *input gate* dan *output gate* dan nilai keluarannya berada di interval negatif satu hingga satu [-1,1] [17]. Fungsi sigmoid dan tanh ditunjukkan pada Persamaan 2.3 dan

Persamaan 2.4 sebagai berikut:

$$\sigma(x) = \frac{1}{1 + e^{-x}} \tag{2.3}$$

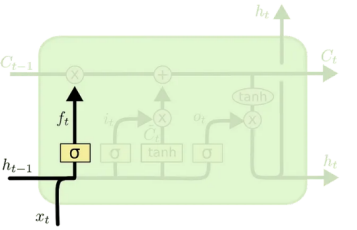
$$\tanh(x) = \frac{e^{x} - e^{-x}}{e^{x} + e^{-x}} \tag{2.4}$$

Keterangan:

$\sigma(x)$	: nilai fungsi sigmoid
$\tanh(x)$	: nilai fungsi tanh
x	: nilai masukan *(input)*

Selanjutnya adalah bentuk struktur dan cara kerja dari struktur LSTM pada tiap gerbang dan memori sel:

1. *Forget gate* mengelola informasi berdasarkan masukan h_{t-1} dan x_t dengan memutuskan apakah data akan disimpan atau dihapus dari *memory cell*. *Forget gate* menggunakan fungsi aktivasi sigmoid, yang menghasilkan *output* antara 0 hingga 1 [0,1]. Fungsi sigmoid akan menghasilkan nilai nol saat berada dalam kisaran $0 \leq \sigma \leq 0.5$, dan nilai satu saat berada dalam kisaran $0.5 \leq \sigma \leq 1$. Jika *output* mendekati 1, semua informasi akan tetap dipertahankan sepenuhnya, sementara jika *output* mendekati 0, maka informasi akan dilupakan [18]. Gambar *forget gate* digambarkan pada Gambar 2.2.



Gambar 2.2 Forget Gate [16].

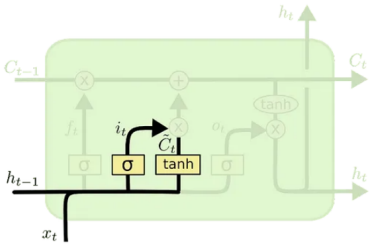
Fungsi *forget gate* ditunjukkan pada Persamaan 2.5 sebagai berikut :

$$f_t = \sigma(Wf[h_{t-1}, X_t] + b_f) \tag{2.5}$$

Keterangan :

f_t	: nilai keluaran *forget gate*
σ	: fungsi sigmoid
W_f	: bobot pada *forget gate*
h_{t-1}	: *hidden state* pada *timestep* sebelumnya
X_t	: *input* pada *timestep t*
b_f	: bias pada *forget gate*

2. Terdapat dua langkah proses dalam pemutusan informasi yang harus ditambahan dalam *cell state*. Hal tersebut dilakukan oleh lapisan sigmoid dan lapisan tanh. Lapisan sigmoid dan tanh menerima *input* berupa keluaran sel sebelumnya (h_{t-1}) dan *timestep* saat ini (x_t). Lapisan dengan aktivasi sigmoid untuk memperbarui informasi, serta lapisan dengan aktivasi tanh untuk menyimpan nilai baru di *cell state* [19]. Kedua output ini bekerja bersama untuk memperbarui *cell state* pada *timestep* saat ini. Gambar *input gate* digambarkan pada Gambar 2.3.



Gambar 2.3 Input Gate [16].

Fungsi *input gate* dan kandidat *cell state* ditunjukkan pada Persamaan 2.6 dan Persamaan 2.7 sebagai berikut:

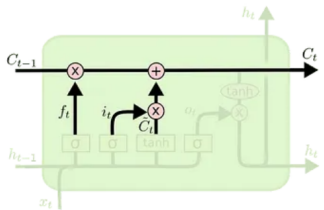
$$i_t = \sigma(W_i[h_{t-1}, X_t] + b_i) \tag{2.6}$$

$$\hat{C}_t = \tanh((Wc[h_{t-1}, X_t] + b_c) \tag{2.7}$$

Keterangan :

i_t	: nilai keluaran *input gate*
σ	: fungsi sigmoid
W_i	: bobot pada *input gate*
h_{t-1}	: *hidden state* pada *timestep* sebelumnya
X_t	: *input* pada *timestep t*
b_i	: bias pada *input gate*
$\hat{C}_t$	: kandidat nilai *cell state* baru
tanh	: fungsi tanh
W_c	: bobot pada *cell state*
b_c	: bias pada *cell state*

3. Pada *cell state*, nilai pada *cell state* sebelumnya akan digantikan oleh nilai *cell state* yang baru. Nilai baru ini diperoleh dengan menggabungkan nilai hasil *output* dari *forget gate* dan *input gate* [20]. Gambar *cell state* digambarkan pada Gambar 2.4.



Gambar 2.4 Cell State [16].

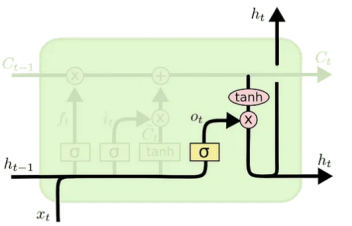
Fungsi *cell state* ditunjukkan pada Persamaan 2.8 sebagai berikut:

$$C_t = f_t \cdot C_{t-1} + i_t \cdot \hat{C}_t \tag{2.8}$$

Keterangan :

C_t	: nilai keluaran *cell state*
f_t	: nilai keluaran *forget gate*
C_{t-1}	: *cell state* pada *timestep* sebelumnya
i_t	: nilai keluaran *input gate*
$\hat{C}_t$	: nilai baru yang ditambahkan ke *cell state* dari perhitungan *i*

4. Proses akhir yaitu menghitung *output* berdasarkan masukan h_{t-1} dan x_t dan filterisasi status sel dan hanya menyimpan informasi yang dibutuhkan. Hal tersebut dijalankan dengan dua proses, yaitu penggunaan lapisan sigmoid (*output gate*) dan mengalikan dengan vektor dari *cell state* yang telah melewati lapisan tanh [21]. Gambar *output gate* digambarkan pada Gambar 2.5.



Gambar 2.5 Output Gate [16].

Fungsi *output gate* ditunjukkan pada Persamaan 2.9 sebagai berikut:

$$o_t = \sigma(W_o[h_{t-1}, X_t] + b_o) \tag{2.9}$$

$$h_t = o_t \cdot \tanh(C_t) \tag{2.10}$$

Keterangan :

o_t	: nilai keluaran *output gate*
σ	: fungsi sigmoid
W_o	: bobot pada *output gate*
h_{t-1}	: *hidden state* pada *timestep* sebelumnya
X_t	: *input* pada *timestep t*
b_o	: bias pada *output gate*
h_t	: *output* pada *timestep t*
C_t	: nilai dari sel memori pada waktu *t*
tanh	: fungsi tanh

2.4 Evaluasi Model

Untuk mengetahui seberapa akurat model yang dibuat perlu dilakukan evaluasi untuk menilai tingkat kesalahan hasil prediksi yang dihasilkan. Matriks evaluasi yang dapat digunakan untuk mengevaluasi ukuran kesalahan dalam peramalan adalah *Mean*

Absolute Error (MAE) dan *Mean Absolute Percentage Error* (MAPE). MAE mengukur tingkat keakuratan model peramalan dengan menghitung rata-rata kesalahan *(error)* dari perbedaan absolut antara prediksi dan nilai aktual pada data [22]. MAE mengantisipasi kesalahan yang bernilai negatif, sehingga dapat menentukan nilai rata-rata kesalahan secara tepat [23] [24]. Pada metode yang diterapkan dapat dikatakan bekerja dengan baik saat nilai *error* memiliki nilai yang rendah. MAE mendekati 0 menunjukkan bahwa kesalahan dalam nilai yang diperkirakan semakin baik dengan kata lain semakin rendah nilai MAE maka semakin baik modelnya [21]. Perhitungan matematis MAE didefinisikan dalam Persamaan 2.11 berikut:

$$\text{MAE} = \frac{1}{N}\sum_{i=1}^{N}|y_i - \hat{y}_i| \tag{2.11}$$

Keterangan :

N	: jumlah total data keseluruhan
y_i	: nilai aktual
$\hat{y}_i$	: nilai hasil prediksi

MAPE merupakan metrik evaluasi yang mengukur rata-rata persentase kesalahan absolut antara nilai aktual dan nilai prediksi [23]. MAPE menghitung nilai prediksi dan nilai aktual dibagi dengan nilai aktual pada periode tersebut, kemudian membagi jumlah data, dan kemudian merata-ratakan kesalahan persentase absolut [25]. Interval galat yang dihasilkan dari peramalan diberikan oleh MAPE. Nilai MAPE semakin rendah menunjukkan kemampuan model peramalan yang digunakan semakin baik, dan sebaliknya. Persamaan MAPE didefinisikan dalam Persamaan 2.12

sebagai berikut:

$$\text{MAPE} = \frac{100\%}{N} \sum_{t=1}^{N} \frac{|y_i - \hat{y}_i|}{|y_i|} \tag{2.12}$$

Keterangan :

N : jumlah total data

y_i : nilai aktual

$\hat{y}_i$: nilai hasil prediksi

MAPE memiliki interval nilai yang dapat dijadikan dasar pengukuran atau pengambilan keputusan mengenai kemampuan suatu model peramalan, interval nilai tersebut tersaji pada Tabel 2.2 sebagai berikut:

Tabel 2.2 Penerimaan nilai MAPE

Interval nilai MAPE	**Keterangan**
$\leq 10\%$	Model peramalan sangat akurat
$10\% < \text{MAPE} \leq 20\%$	Model peramalan akurat
$20\% < \text{MAPE} \leq 50\%$	Model peramalan layak
$> 50\%$	Model peramalan tidak akurat

BAB III

METODE PENELITIAN

3.1 Data Penelitian

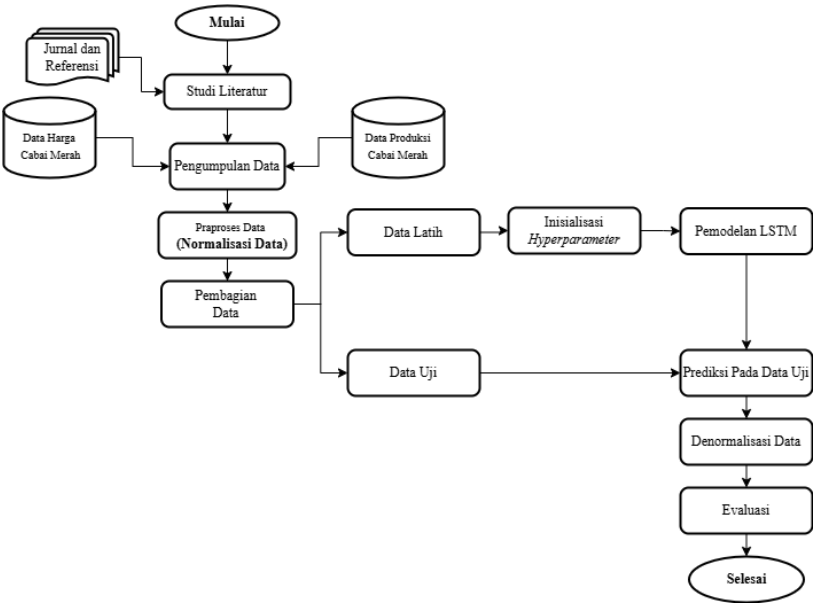
Data yang digunakan pada penelitian ini adalah harga cabai merah dan jumlah produksi cabai merah di Provinsi Lampung. Data harga cabai merah di Provinsi Lampung diperoleh melalui situs Pusat Informasi Harga Pangan Strategis Bank Indonesia. Sedangkan untuk data jumlah produksi cabai merah di Provinsi Lampung diperoleh dari Badan Pusat Statistik (BPS) Lampung. Rentang waktu yang akan digunakan yaitu dari bulan Januari 2019 hingga Desember 2023 dengan deksripsi data sebagai berikut:

Tabel 3.1 Atribut Data

Atribut	Deskripsi
Tanggal (MM/YYYY)	Menunjukkan tanggal data diamati
Harga (Rupiah)	Menunjukkan harga cabai merah dalam satuan Rp/Kg
Produksi (Kuintal)	Menunjukkan jumlah produksi cabai merah

3.2 Tahapan Penelitian

Pelaksanaan penelitian dilakukan melalui beberapa tahapan yang akan dilakukan. Alur penelitian ditampilkan pada Gambar 3.1.



Gambar 3.1 Tahapan Penelitian

Beberapa tahapan penelitian ini dijabarkan sebagai berikut :

1. **Studi literatur**: Pada tahap ini peneliti mencari referensi mengenai studi literatur yang berkaitan dengan penelitian.
2. **Pengumpulan data**: Proses pengambilan data harga cabai merah dari tahun 2019 sampai dengan 2023 yang bersumber dari *website* Pusat Informasi Harga Pangan Strategis (PIHPS) dan jumlah produksi cabai merah dari tahun 2019 sampai dengan 2023 dari BPS yang akan digunakan untuk penelitian.
3. **Normalisasi data**: Pada tahap ini dilakukan normalisasi data menggunakan bantuan *library* Tensorflow *MinMax Scaler* yaitu mengubah nilai data menjadi skala antara [0,1].
4. **Pembagian data**: Membagi data menjadi data latih dan data uji. Proses pembagian data dilakukan secara berurutan karena data yang digunakan adalah data deret waktu atau *timeseries*

sehingga tidak dilakukan secara acak karena akan merusak urutan waktu yang digunakan.

5. **Inisialisasi *hyperparameter***: Sebelum proses *training* model menggunakan data latih terdapat beberapa parameter yang harus ditentukan, proses ini dinamakan *hyperparamer tunning*, parameter tersebut adalah:

Tabel 3.2 *Hyperparameter*

Hyperparameter	**Nilai**
Hidden Layer LSTM	1, 2
Neuron	2, 4, 8, 16, 32
Batch Size	1, 2, 4, 8, 16
Sequence	6
Epoch	500

   (a) *Hidden Layer* LSTM adalah jumlah lapisan LSTM yang digunakan dalam model.
   (b) *Neuron* adalah jumlah unit dalam satu lapisan LSTM.
   (c) *Sequence* adalah panjang jumlah langkah waktu *(timestep)* dari data historis yang dimasukkan ke dalam model LSTM untuk memprediksi data ke depan.
   (d) *Batch size* adalah jumlah sampel data yang diproses dalam satu iterasi ketika melatih model.
   (e) *Epoch* adalah jumlah iterasi penuh terhadap seluruh dataset pelatihan.

6. **Pemodelan LSTM**: Untuk mencapai hasil yang digunakan untuk prediksi, pembuatan model LSTM membutuhkan beberapa tahap. Tahapan-tahapan ini termasuk melatih jaringan LSTM dan menginisialisasi parameter. Tahapan-tahapan ini dilakukan pada lapisan LSTM sebagai berikut:
   (a) **Inisialisasi Parameter**: Pada tahap ini, bobot dan bias

diinisialisasi secara acak menggunakan *library Tensorflow*.

(b) ***Forward Pass (Step Forward)***: Langkah selanjutnya yaitu proses perhitungan *gate* dan *cell state*.

- ***Forget Gate***: Menghitung seberapa banyak informasi dari timestep sebelumnya yang harus dilupakan.
- ***Input Gate***: Menentukan informasi baru yang akan ditambahkan ke *cell state*.
- ***Cell State***: Memperbarui *cell state* berdasarkan hasil *Forget Gate* dan *Input Gate*.
- ***Output Gate***: Menghitung *hidden state* atau keluaran LSTM untuk *timestep* saat ini, yang akan menjadi *input* untuk *timestep* berikutnya.

(c) **Perhitungan *Loss Function***: Setelah *Forward Pass*, keluaran model dibandingkan dengan target *output*. *Mean Absolute Error* (MAE) digunakan sebagai fungsi *loss* untuk mengukur perbedaan antara prediksi model dan target sebenarnya. Ini memberikan gambaran tentang seberapa jauh prediksi dari nilai target.

(d) ***Backpropagation Through Time* (BPTT)**: Setelah menghitung *loss*, dilakukan *backpropagation* untuk menghitung gradien dari *loss* terhadap setiap parameter (bobot dan bias) dalam model. Gradien ini menunjukkan arah dan seberapa besar perubahan yang diperlukan untuk meminimalkan *loss*.

(e) **Optimasi dan Perbarui Bobot**: Setelah gradien dihitung, algoritma optimasi Adam digunakan untuk memperbarui bobot dan bias. Bobot dan bias diperbarui sesuai dengan gradien yang telah dihitung, untuk mendekatkan fungsi *loss* ke titik minimum.

(f) **Iterasi**: Pengulangan proses *forwards pass*, perhitungan *loss*, BPTT, dan pembaharuan bobot diulang untuk sejumlah epoch yang telah ditentukan.

7. **Prediksi data uji**: Setelah model selesai dilatih menggunakan data latih, model diuji menggunakan data uji untuk mengukur seberapa baik model dalam menggeneralisasi data baru.
8. **Denormalisasi Data**: Mengonversi kembali nilai yang telah dinormalisasi kembali ke bentuk aslinya.
9. **Evaluasi Model**: Memeriksa kinerja model dengan data uji yang sudah didenormalisasi. Evaluasi akurasi model dilakukan menggunakan metrik MAE dan MAPE untuk menilai seberapa baik model dalam memprediksi data.

BAB IV

HASIL DAN PEMBAHASAN

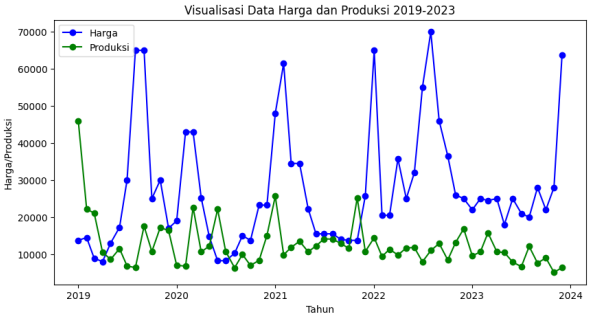
4.1 Dataset

Penelitian ini menggunakan dua variabel yaitu harga dan produksi cabai merah. Dataset harga cabai merah bersumber dari website Pusat Informasi Harga Pangan Strategis Nasional (PIHPS). Pada situs tersebut peneliti menentukan data yang akan diambil yaitu komoditas cabai merah besar pada tingkat produsen dengan wilayah Provinsi Lampung dan tipe laporan bulanan dengan rentang waktu yang dimulai dari bulan Januari 2019 hingga Desember 2023. Sedangkan data produksi cabai merah yang bersumber dari Badan Pusat Statistik (BPS) Lampung melalui Dinas Ketahanan Pangan, Tanaman Pangan dan Hortikultura Provinsi Lampung. Dataset penelitian ditunjukkan pada Tabel4.1:

Tabel 4.1 Dataset Penelitian

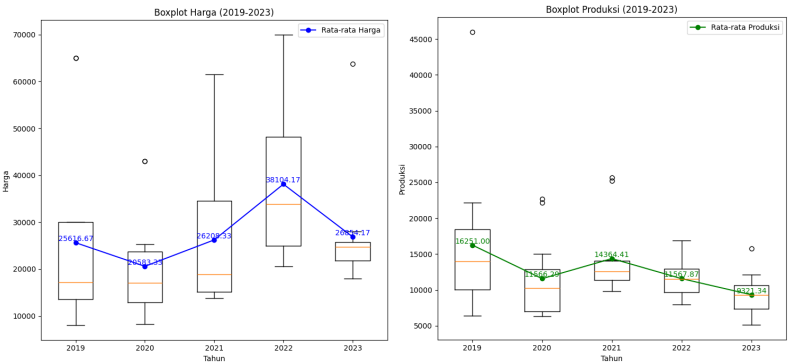
Tanggal	**Harga (Rp/Kg)**	**Produksi (Kuintal)**
2019-01-01	13750	46000
2019-02-01	14500	22157
2019-03-01	8900	21098
....	...	...
2023-12-02	63750	63743

Berikut visualisasi pergerakan fluktuasi harga dan produksi cabai merah pada periode Januari 2018 hingga Desember 2023 yang dapat dilihat pada Gambar 4.1 sebagai berikut.



Gambar 4.1 Visualisasi Data Penelitian

Pada Gambar 4.1 garis biru menunjukkan variabel harga dan garis hijau menunjukkan variabel produksi yang bergerak secara fluktuatif selama kurun waktu 5 tahun. Hubungan antara harga dan produksi cabai merah terlihat adanya hubungan terbalik pada beberapa periode. Hal tersebut dapat dilihat pada awal tahun 2019 dimana saat angka produksi tinggi, harga cabai mengalami penurunan. Sebaliknya pada tahun 2020, 2021, 2022, dan 2023 pada awal tahun ketika produksi mengalami penurunan terjadi kenaikan harga pada cabai merah. Hal ini terjadi karena beberapa faktor salah satunya disebabkan oleh tinggi rendahnya permintaan dan pasokan cabai itu sendiri, semakin tinggi pasokan maka semakin murah harga cabai merah. Sedangkan semakin sedikit pasokan, maka semakin mahal harga cabai merah [26]. Selain itu, terdapat pola musiman pada variabel harga, di mana harga cabai merah cenderung meningkat tajam pada awal tahun. Hal ini terkait dengan rendahnya jumlah produksi pada awal tahun akibat berbagai faktor, seperti permintaan dan penawaran, curah hujan, serta biaya produksi [27].



(a) Boxplot Data Harga Cabai Merah **(b)** Boxplot Data Produksi Cabai Merah

Gambar 4.2 Visualisasi Boxplot

Gambar 4.2a menggambarkan boxplot harga cabai merah dan Gambar 4.2b menggambarkan boxplot produksi cabai merah per tahun. Selama periode 2018-2023, harga cabai merah juga menunjukkan pola yang fluktuatif pada setiap tahunnya. Sedangkan produksi cabai merah mengalami penurunan rata-rata produksi. Rata-rata harga cabai merah terendah terdapat pada tahun 2020 dan tertinggi pada tahun 2022. Peningkatakan rata-rata harga cabai merah terjadi pada tahun 2020 hingga 2022 dan kembali turun pada tahun 2023. Hal ini disebabkan karena adanya penurunan produksi cabai merah pada periode yang sama. Ada beberapa *outlier* atau pencilan pada harga dan produksi cabai merah menunjukkan adanya nilai data yang sangat jauh dari nilai-nilai lainnya. Namun, pada penelitian ini tidak dilakukan penanganan *outlier* karena data tersebut merupakan bagian dari data pengamatan yang berfluktuatif.

4.2 Normalisasi Data

Normalisasi merupakan bagian dalam praproses data, yaitu mempersiapkan data sebelum dimasukan ke dalam model. Dalam penelitian ini normalisasi dilakukan dengan menggunakan

Persamaan 2.1 dan diimplementasikan dengan bantuan *library scikit-learn*, yaitu *MinMax Scaler*. Proses normalisasi ini mengubah nilai data aktual yang sebelumnya berada dalam rentang ribuan menjadi nilai dalam rentang [0,1]. Normalisasi dilakukan untuk mempercepat proses pembelajaran pada model dan untuk memastikan bahwa nilai *input* berada dalam interval yang sama [14]. Dataset yang telah dinormalisasi inilah yang akan digunakan dalam tahap pemodelan LSTM. Tabel dibawah merupakan perbandingan data sebelum dan sesudah normalisasi, pada tabel 4.2 menyajikan data sebelum dilakukan normalisasi dan Tabel 4.3 menunjukkan data penelitian setelah dinormalisasi.

Tabel 4.2 Dataset Sebelum Normalisasi

Tanggal	**Harga (Rp/Kg)**	**Produksi (Kuintal)**
2019-01-01	13750	46000
2019-02-01	14500	22157
2019-03-01	8900	10540
2019-04-01	8000	16000
...	...	...
2023-12-01	63750	6374,3

Tabel 4.3 Dataset Setelah Normalisasi

Tanggal	**Harga (Rp/Kg)**	**Produksi (Kuintal)**
2019-01-01	0,0927	1
2019-02-01	0,1048	0,4169
2019-03-01	0,0145	0,3910
2019-04-01	0	0,1328
...	...	...
2023-12-01	0,8991	0,0310

4.3 Pembagian Data

Pada proses pembagian data, dataset dibagi menjadi subset pelatihan dan pengujian. Subset pelatihan untuk melatih model, sementara subset pengujian untuk menguji model setelah pelatihan. Rasio pembagian data yang digunakan adalah 60%:40% atau 3 tahun pertama sebagai data latih dan 2 tahun terakhir sebagai data uji. Pembagian data dapat dibuat demikian karena data penelitian merupakan data deret waktu sehingga tidak dapat diacak.

Tabel 4.4 Pembagian Data Latih dan Uji

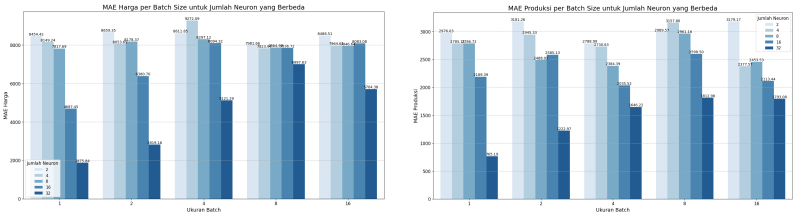
Komposisi	Jumlah Data Latih	Jumlah Data Uji
60%:40%	36	24

4.4 Pengujian Model LSTM

Proses pengujian LSTM dalam penelitian ini terdiri dari beberapa model dan skenario yaitu jumlah *hidden layer* LSTM, jumlah *neuron* dan *batch size*. Skenario yang diuji meliputi penggunaan 1 dan 2 *hidden layer*. Untuk jumlah *neuron*, variasi yang diuji adalah 2, 4, 8, 16, dan 32. Sedangkan untuk *batch size*, variasi yang digunakan adalah 1, 2, 4, 8, dan 16. Parameter LSTM lainnya yang digunakan adalah panjang *sequence* 6 dan 500 *epoch*. Berikut adalah hasil beberapa percobaan yang telah dilakukan.

4.4.1 1 *Hidden Layer* LSTM

Pengujian pertama dilakukan dengan menggunakan variasi jumlah *neuron* dan *batch size* pada 1 *hidden layer* LSTM. Hasil evaluasi MAE yang telah dilakukan ditunjukkan pada Gambar 4.3. Sedangkan evaluasi MAPE ditunjukkan pada Gambar 4.4.

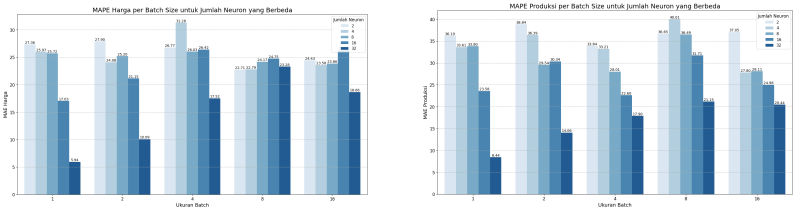


(a) MAE Harga **(b)** MAE Produksi

Gambar 4.3 Visualisasi Evaluasi MAE 1 *Hidden Layer* LSTM

Gambar 4.3 menunjukkan hasil evaluasi pengujian dari beberapa skenario model. Berdasarkan visualisasi tersebut, terlihat bahwa

jumlah *neuron* dan *batch size* memiliki pengaruh terhadap hasil pemodelan melalui evaluasi MAE untuk prediksi harga maupun produksi cabai merah. Pada Gambar 4.3a yaitu grafik evaluasi MAE variabel harga per *batch size*, terlihat bahwa penambahan jumlah neuron dari 2 menjadi 32 secara konsisten memberikan perubahan berupa penurunan nilai MAE di semua variasi *batch size*. Model dengan 32 *neuron* selalu menghasilkan MAE terendah, terutama pada *batch size* 1 dengan niai MAE sebesar 1875,84. Dengan demikian, dapat dilihat dari kecenderungan nilai MAE yang lebih rendah pada *batch size* kecil menunjukkan bahwa pemilihan *batch size* yang kecil membantu model untuk lebih akurat dalam melakukan prediksi. Pada Gambar 4.3b yaitu evaluasi MAE variabel produksi juga menunjukkan model dengan 32 *neuron* memberikan performa terbaik, dengan MAE produksi terendah juga pada *batch size* 1 dengan nilai 765,19. Pada variabel produksi juga menunjukkan kinerja model yang lebih baik pada *batch size* kecil.



(a) MAPE Harga **(b)** MAPE Produksi

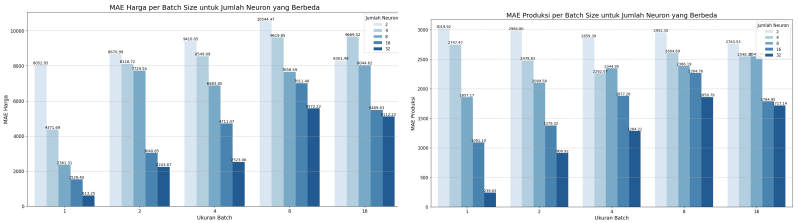
Gambar 4.4 Visualisasi Evaluasi MAPE 1 *Hidden Layer* LSTM

Pada Gambar 4.4 merupakan visualisasi grafik evaluasi MAPE pada variabel harga dan produksi cabai merah. Visualisasi MAPE ini menunjukkan bahwa kombinasi 32 *neuron* dengan *batch size* 1 menghasilkan nilai MAPE terendah yaitu 5,94% untuk variabel harga dan 8,44% untuk variabel produksi. Secara keseluruhan, berdasarkan hasil evaluasi ini dapat disimpulkan bahwa

penggunakan jumlah *neuron* 32 dan *batch size* 1 menghasilkan kesalahan prediksi terendah baik dalam metrik MAE maupun MAPE untuk variabel harga dan produksi dengan menggunakan 1 *hidden layer* LSTM.

4.4.2 2 *Hidden Layer* LSTM

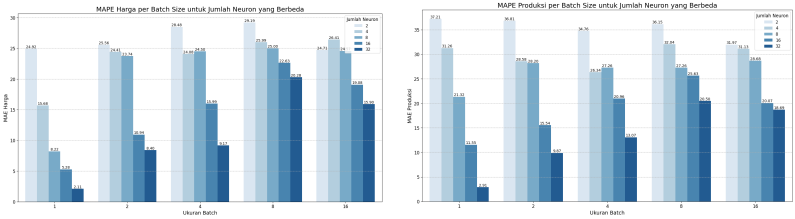
Pengujian kedua dilakukan dengan menggunakan variasi jumlah *neuron* dan *batch size* pada 2 *hidden layer* LSTM. Hasil evaluasi MAE pada model ditunjukkan pada Gambar 4.5. Sedangkan evaluasi MAPE ditunjukkan pada Gambar 4.6.



(a) MAE Harga **(b)** MAE Produksi

Gambar 4.5 Visualisasi Evaluasi MAE 2 *Hidden Layer* LSTM

Gambar 4.5 yaitu grafik perbandingan evaluasi MAE untuk variabel harga dan produksi cabai merah pada model dengan menggunakan beberapa skenario. Terlihat bahwa penambahan jumlah *neuron* pada setiap percobaan jumlah *batch size* menurunkan nilai MAE. *Neuron* 32 memberikan performa terbaik dengan nilai evaluasi terendah terdapat pada percobaan dengan menggunakan *batch size* 1 baik adalah variabel harga maupun produksi cabai merah masing-masing yaitu 613.25 dan 239.03.



(a) MAPE Harga **(b)** MAPE Produksi

Gambar 4.6 Visualisasi Evaluasi MAPE 1 *Hidden Layer* LSTM

Gambar 4.6 merupakan visualisasi grafik evaluasi MAPE pada variabel harga dan produksi cabai merah. Grafik evaluasi MAPE menunjukkan juga bahwa penggunakan 32 *neuron* dan 1 *batch size* menghasilkan nilai MAPE terendah yaitu 2.11% untuk variabel harga dan 2.91% untuk variabel produksi. Hasil evaluasi terbaik ini menunjukkan nilai yang lebih rendah dari percobaan penggunaan 1 *hidden layer*. Sehingga, hasil evaluasi ini dapat disimpulkan bahwa penambahan *hidden layer* dengan menggunakan skenario *neuron* dan *batch size* yang sama memberikan hasil baik yaitu dengan penurunan evaluasi baik MAE maupun MAPE.

Berdasarkan hasil percobaan pada skenario *hidden layer* LSTM dengan variasi jumlah *neuron* dan *batch size*, diperoleh bahwa konfigurasi dengan 32 *neuron* menunjukkan performa terbaik dalam penelitian ini. Tidak ada aturan pasti untuk jumlah *neuron* yang optimal dalam prediksi deret waktu karena tergantung pada data yang digunakan dalam percobaan. Oleh karena itu, untuk memperoleh hasil terbaik, diperlukan serangkaian percobaan [28]. Hasil percobaan konfigurasi pembagian data dan *neuron* ini sesuai dengan penelitian sebelumnya bahwa seiring bertambahnya jumlah *neuron* pada lapisan tersembunyi, keakuratan juga cenderung meningkat. Namun, peningkatan ini hanya berlangsung hingga titik tertentu, yang dalam penelitian ini terjadi pada jumlah *neuron*

sebanyak 32. Di luar ambang batas ini, menambahkan lebih banyak *neuron* dapat menyebabkan *overfitting* pada model [29].

Berdasarkan hasil pengujian jumlah *batch size* menunjukkan bahwa jumlah *batch size* 1 memiliki hasil yang optimal. Hal ini mengindikasikan bahwa model mampu melakukan pembelajaran dengan lebih baik pada ukuran *batch* kecil karena jumlah data yang sedikit. Hasil pengujian jumlah *batch size* sejalan dengan penelitian sebelumnya yang menunjukkan bahwa *batch size* kecil seringkali memberikan performa generalisasi yang lebih baik dan ukuran *batch* yang terlalu besar akan memberikan hasil yang kurang optimal, namun hal ini juga disesuaikan oleh dari data yang digunakan dalam penelitian[30]. Dalam konteks penelitian ini, penggunaan *batch size* 1 menunjukkan hasil yang optimal, karena jumlah data yang relatif sedikit. Ukuran *batch* yang kecil membantu mengurangi variasi bobot pada setiap iterasi, sehingga proses pembelajaran menjadi lebih stabil dan akurat.

Berdasarkan percobaan jumlah *hidden layer* LSTM menunjukkan bahwa penambahan jumlah *layer* pada model LSTM memberikan pengaruh terhadap peningkatan performa model. Hasil ini menunjukkan bahwa arsitektur LSTM dengan beberapa lapisan dapat menangkap pola kompleks dalam data deret waktu. Hasil percobaan variasi jumlah *layer* ini sesuai dengan penelitian sebelumnya bahwa seiring bertambahnya jumlah *layer* dapat meningkatkan akurasi model namun hal ini juga disesuaikan pada karakteristik data [31].

Sedangkan pemilihan *hyperparameter* lain seperti panjang *sequence* selama 6 bulan dalam model LSTM didasarkan pada pola musiman produksi dan harga cabai merah di Indonesia. Produksi cabai sangat dipengaruhi oleh musim tanam, di mana musim kemarau cenderung menjadi musim panen raya, sedangkan musim

hujan sering menyebabkan gagal panen yang berdampak pada lonjakan harga. Dengan panjang *sequence* 6 bulan, model dapat menangkap satu siklus musiman penuh yang merepresentasikan fluktuasi pasokan dan harga secara lebih akurat [32].

Pemilihan jumlah *epoch* sebanyak 500 didasarkan pada hasil uji coba yang menunjukkan bahwa pada titik ini model mencapai performa terbaik, ditunjukkan dengan nilai evaluasi yang paling rendah dan tidak mengalami *overfitting*. Penambahan *epoch* hingga 600 atau 700 justru menyebabkan model kehilangan kemampuan generalisasi karena terlalu menyesuaikan diri dengan data latih, sedangkan penggunaan *epoch* di bawah 500 menghasilkan akurasi yang lebih rendah karena model belum cukup belajar dari pola data. Pemilihan jumlah *epoch* yang tepat dapat meningkatkan performa model, namun penggunaan *epoch* yang terlalu besar dapat memperpanjang waktu pelatihan dan meningkatkan risiko *overfitting* [31] [33].

4.5 Analisis Hasil Prediksi Model Terbaik

Setelah didapatkan model terbaik yaitu model LSTM menggunakan kombinasi *hyperparameter* yaitu 2 *hidden layer* LSTM, 32 *neuron*, 1 *batch size* dengan panjang 6 *sequence* dan *epoch 500*. Arsitektur akhir model LSTM yang digunakan terdiri dari 3 lapisan, yaitu 2 lapisan LSTM dan 1 lapisan output. Arsitektur model ditampilkan pada rincian dibawah ini.

```
Model: "sequential"
_________________________________________________________________
 Layer (type)                Output Shape              Param #
=================================================================
 lstm_1 (LSTM)               (None, 6, 32)             4480
 lstm_2 (LSTM)               (None, 32)                8320
 dense (Dense)               (None, 2)                 66
```

```
=================================================================
Total params: 12866 (50.26 KB)
Trainable params: 12866 (50.26 KB)
Non-trainable params: 0 (0.00 Byte)
```

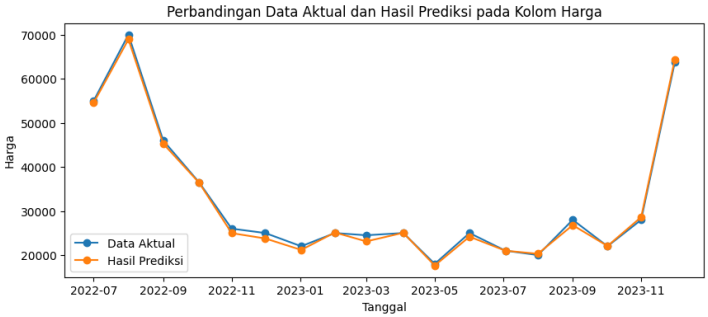
Arsitektur model LSTM di atas terdiri dari 3 *layer* yaitu, 2 LSTM *(hidden layer)* dan 1 Dense *layer output*. Pada LSTM *layer* 1 menghasilkan *output* 32 unit LSTM dan *layer* ini menerima *input* dengan panjang *sequence* 6. Jumlah total parameter pada *layer* ini ada 4480, yang mencakup bobot dan bias untuk *gate* dalam LSTM. Pada LSTM *layer* 2 terdapat 32 unit karena hanya mengembalikan *output* terakhir dari *sequence*. Jumlah total parameter pada *layer* ini ada 8322. *Layer* terakhir adalah *layer* Dense dengan 2 unit yang merepresentasikan dua target prediksi, yaitu harga dan produksi. *Layer* ini memiliki 66 parameter. Secara keseluruhan, model ini memiliki total 12.866 parameter.

Selanjutnya Tabel 4.5 menyajikan hasil prediksi harga dan produksi cabai merah oleh model LSTM pada data uji dalam bentuk nilai yang telah didenormalisasi ke skala aslinya. Data ini merepresentasikan periode waktu dari Juli 2022 hingga Desember 2023. Jumlah data yang ditampilkan sebanyak 18 baris, yang berbeda dari jumlah data uji keseluruhan yang seharusnya berjumlah 24. Hal ini disebabkan oleh penggunaan panjang *sequence* selama 6 bulan pada model LSTM, yang secara otomatis mengurangi jumlah titik data yang dapat diprediksi di awal periode pengujian. Karena model membutuhkan enam bulan data historis untuk menghasilkan satu prediksi, maka prediksi baru dapat dimulai dari bulan ke-7 dalam rentang data uji.

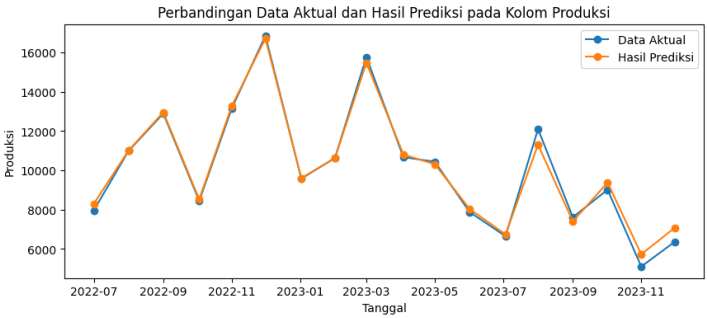
Tabel 4.5 Data Harga dan Produksi

No	Tanggal	Harga	Produksi
1	2022-07-01	54555	8298
2	2022-08-01	68934	11010
3	2022-09-01	45272	12962
4	2022-10-03	36410	8528
5	2022-11-01	24978	13279
6	2022-12-01	23765	16713
7	2023-01-02	21169	9605
8	2023-02-01	25118	10631
9	2023-03-01	23102	15474
10	2023-04-03	25053	10804
11	2023-05-01	17626,	10313
12	2023-06-01	24175	8039
13	2023-07-03	20991	6742
14	2023-08-01	20295	11309
15	2023-09-01	26788	7406
16	2023-10-02	22059	9378
17	2023-11-01	28611	5729
18	2023-12-01	64421	7087

Setelah mendapatkan nilai prediksi dilakukan visualisasi terhadap perbandingan nilai hasil prediksi yang telah didenormalisasi dengan data aktual dalam kurun waktu yang sama. Gambar 4.7 menampilkan perbandingan antara nilai hasil prediksi dan aktual pada variabel harga. Sedangkan Gambar 4.8 menampilkan perbandingan antara nilai hasil prediksi dan aktual pada variabel produksi.



Gambar 4.7 Grafik Perbandingan Variabel Harga

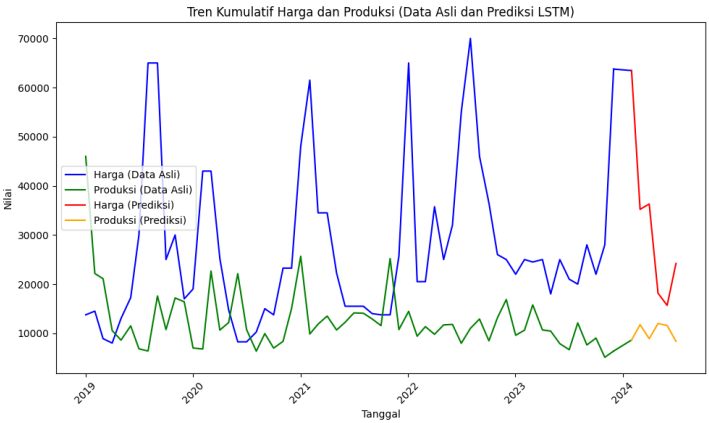


Gambar 4.8 Grafik Perbandingan Variabel Produksi

Berdasarkan Gambar 4.7 dan Gambar 4.8 dapat diamati bahwa nilai prediksi yang dihasilkan oleh model mampu mengikuti pola data aktual baik pada variabel harga maupun produksi. Meskipun ada beberapa titik yang tidak akurat namun model ini tetap menunjukkan kemampuan generalisasi yang baik.

Selanjutnya, hasil peramalan harga dan produksi cabai merah pada masa depan menggunakan model yang telah dibuat menghasilkan visualisasi grafik yang dapat diamati bahwa nilai peramalan 6 bulan yang akan datang memiliki pola yang hampir sama dengan pola pada periode sebelumnya. Pada Gambar 4.9 garis berwarna biru menunjukkan data asli pada variabel harga dan garis merah

menunjukkan peramalan selama 6 bulan kedepan pada variabel harga. Garis berwarna hijau menunjukkan data asli pada variabel produksi dan garis oranye menunjukkan peramalan selama 6 bulan kedepan pada variabel produksi.



Gambar 4.9 Peramalan Selama 6 Bulan Kedepan

Hasil diatas memprediksikan adanya fluktuasi selama 6 bulan dalam periode Januari sampai Juni tahun 2024. Prediksi menunjukkan puncak harga sekitar Rp60.000 pada periode awal yang kemudian mengalami penurunan bertahap dan mengalami kenaikan lagi sekitar Rp30.000 pada pertengahan tahun. Pola ini mengindikasikan potensi stabilisasi harga di masa mendatang karena tidak mencapai nilai tertinggi seperti pada awal tahun. Pada variabel produksi, model memprediksikan nilai produksi akan bergerak dalam rentang 7000 hingga 17000 kuintal dengan pola fluktuasi yang tidak terlalu tinggi. Hasil prediksi menunjukkan adanya pola hubungan antara harga dan produksi. Ketika harga diprediksi naik, tingkat produksi menurun, begitu juga sebaliknya. Pola ini sesuai dengan teori dasar ekonomi tentang hubungan antara *supply* (penawaran) dan *demand* (permintaan) [34].

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil pengujian dalam penelitian ini, dapat disimpulkan bahwa prediksi harga dan produksi cabai merah di Provinsi Lampung berhasil dilakukan menggunakan algoritma *Long Short-Term Memory* (LSTM). Dari proses pengujian ini dapat diketahui nilai parameter yang optimal pada prediksi harga dan produksi cabai merah di Provinsi Lampung menggunakan data dari Januari 2019 hingga Desember 2023. Pengujian menunjukkan bahwa model memberikan performa terbaik saat menggunakan kombinasi *hyperparamter* yaitu, 2 *hidden layer* LSTM, 1 *batch size*, 32 *neuron*, 6 *sequence length*, dan *epoch* 500. Model dengan konfigurasi tersebut menghasilkan nilai evaluasi nilai MAE yaitu 625,46 untuk variabel harga dan 327,67 untuk variabel produksi. Sementara itu untuk evaluasi MAPE yaitu 2,06% untuk variabel harga dan 3,75% untuk variabel produksi. Model ini menghasilkan nilai prediksi pada periode 6 bulan kedepan yaitu Rp30.000 hingga Rp60.000 untuk harga cabai merah dan 7000 hingga 17000 kuintal untuk produksi cabai merah.

5.2 Saran

Hal-hal penting terkait pelaksanaan penelitian yang perlu diperhatikan kedepannya adalah

1. Penambahan jumlah fitur yang memengaruhi fluktuasi pada harga cabai merah seperti cuaca, curah hujan, jumlah impor dan ekspor dan lain-lain.

2. Penambahan data historis yang lebih banyak untuk melakukan peramalan yang lebih baik.
3. Melakukan pengkajian ulang dengan uji coba *hyperparameter* yang berbeda yang dapat mempengaruhi hasil prediksi kedepannya untuk mendapatkan hasil yang lebih baik.
4. Menggunakan teknik tambahan seperti *cross validation* untuk memastikan bahwa model tidak hanya berkinerja baik pada dataset tertentu tetapi juga memiliki kemampuan generalisasi yang lebih baik.

DAFTAR PUSTAKA

[1] N. Palar, Pangemanan, dan E. G. Tangkere, "Faktor-Faktor Yang Mempengaruhi Harga Cabai di Kota Manado", *Agri-sosioekonomi*, vol. 12, 2016.

[2] D. Anjayani dan E. Ambarwati, "Mutu dan daya simpan buah cabai merah (capsicum annuum l.) sebagai tanggapan terhadap berbagai jenis pupuk hayati", id, *Vegetalika*, vol. 10, no. 3, hlmn. 159–173, Agt. 2021. sumber: https://jurnal.ugm.ac.id/jbp/article/view/47817.

[3] Mas'ud dan S. Wayuningsih, "Statistik konsumsi pangan tahun 2023", Badan Pusat Statsitik, tech. rep., 2023. sumber: https://satudata.pertanian.go.id/assets/docs/publikasi/Buku_Statsitik_Konsumsi_Pangan_2023.pdf.

[4] A. Yuditya, A. Hardjanto, dan U. Sehabudin, "Fluktuasi Harga dan Integrasi Pasar Cabai Merah Besar (Studi Kasus: Pasar Induk kramat Jati dan Pasar Eceran di DKI Jakarta)", *Indonesian Journal of Agriculture Resource and Environmental Economics*, vol. 2, no. 1, hlmn. 1–13, 2023.

[5] A. Puspa Nur Ritma, Y. Hidayat, dan D. Yusti Faidah, "Peramalan harga aneka cabai menggunakan metode long short term memory (lstm): Studi kasus di provinsi jawa barat", *Prosiding Seminar Nasional Statistika Aktuaria*, vol. 2, no. 1, hlmn. 399–406, 2023. sumber: https : / / prosidingsnsa . statistics . unpad . ac . id / ?journal = prosidingsnsa & amp ; page = article&op=view&path%5B%5D=331.

[6] N. Hidayati, S. Anwar, dan R. Rahmah, "Peramalan harga cabai merah sebagai upaya menjaga stabilitas inflasi kota banda aceh", *Agriekonomika*, vol. 11, no. 1, hlmn. 31–42, Agt. 2022. sumber: https : / / journal . trunojoyo . ac . id / agriekonomika/article/view/11380.

[7] M. David, I. Cholissodin, dan N. Yudistira, "Prediksi Harga Cabai menggunakan Metode Long-Short Term Memory (Case Study : Kota Malang)", *Jurnal Pengembangan Teknologi Informasi dan Ilmu Komputer*, vol. 7, no. 3, hlmn. 1214–1219, 2023. sumber: https://j-ptiik.ub.ac.id/index.php/j-ptiik/article/view/12406.

[8] "Laporan Perekonomian Provinsi Lampung", Bank Indonesia, tech. rep., 2022. eprint: arXiv : 1011 . 1669v3. sumber: https://www.bi.go.id/id/publikasi/laporan/lpp/Pages/Laporan - Perekonomian - Provinsi - Lampung - November - 2022.aspx.

[9] A. Restu, H. Dwika, dan D. Avianto, "Jurnal Indonesia : Manajemen Informatika dan Komunikasi Implementasi Algoritma LSTM untuk Prediksi Harga Cabai Merah Keriting di Yogyakarta Abstrak Jurnal Indonesia : Manajemen Informatika dan Komunikasi", *Jurnal Indonesia : Manajemen Informatika dan Komunikasi*, vol. 5, no. 1, hlmn. 635–648, 2024.

[10] A. W. Saputra, A. P. Wibawa, U. Pujianto, A. B. Putra Utama, dan A. Nafalski, "LSTM-based Multivariate Time-Series Analysis: A Case of Journal Visitors Forecasting", *ILKOM Jurnal Ilmiah*, vol. 14, no. 1, hlmn. 57–62, 2022.

[11] T. Jaelani, "Machine Learning untuk Prediksi Produksi Gula Nasional", *JMPM (Jurnal Material dan Proses Manufaktur)*, vol. 6, no. 1, hlmn. 31–36, 2022.

[12] P. Hastowo Ardi, "Peramalan Permintaan Ekspor Non Migas Indonesia Menggunakan Long Short Term Memory", 2023.

[13] I. Permana dan F. N. S. Salisah, "Pengaruh Normalisasi Data Terhadap Performa Hasil Klasifikasi Algoritma Backpropagation", *Indonesian Journal of Informatic*

Research and Software Engineering (IJIRSE), vol. 2, no. 1, hlmn. 67–72, 2022.

[14] H. S. Izzadiana, H. Napitupulu, dan F. Firdaniza, "Peramalan Data Univariat Menggunakan Metode Long Short Term Memory", *SisInfo : Jurnal Sistem Informasi dan Informatika*, vol. 5, no. 2, hlmn. 29–39, 2023.

[15] J. Cahyani, S. Mujahidin, dan T. P. Fiqar, "Implementasi Metode Long Short Term Memory (LSTM) untuk Memprediksi Harga Bahan Pokok Nasional", *Jurnal Sistem dan Teknologi Informasi (JustIN)*, vol. 11, no. 2, hlmn. 346, 2023.

[16] C. Olah. "Understanding LSTM Networks." (), sumber: https://colah.github.io/posts/2015-08-Understanding-LSTMs/.

[17] H. He dan F. Luo, "Study of LSTM Air Quality Index Prediction Based on Forecasting Timeliness", *IOP Conference Series: Earth and Environmental Science*, vol. 446, no. 3, 2020.

[18] L. Wiranda dan M. Sadikin, "Penerapan Long Short Term Memory Pada Data Time Series Untuk Memprediksi Penjualan Produk Pt. Metiska Farma", *Jurnal Nasional Pendidikan Teknik Informatika (JANAPATI)*, vol. 8, no. 3, hlmn. 184–196, 2019.

[19] A. S. Bayangkari Karno, "Analisis Data Time Series Menggunakan LSTM (Long Short Term Memory) Dan ARIMA (Autocorrelation Integrated Moving Average) Dalam Bahasa Python.", *Ultima InfoSys : Jurnal Ilmu Sistem Informasi*, vol. 11, no. 1, hlmn. 1–7, 2020.

[20] M. W. P. Aldi, Jondri, dan A. Aditsania, "Analisis dan Implementasi Long Short Term Memory Neural Network Untuk Prediksi Harga Bitcoin", *e-Proceeding of Engineering*, vol. 5, no. 2, hlmn. 3548–3555, 2018.

[21] A. Arkadia, B. Hananto, dan D. S. Prasvita, “Optimasi Long Short Term Memory Dengan Adam Menggunakan Data Udara Kota DKI Jakarta”, *Seminar Nasional Mahasiswa Ilmu Komputer dan Aplikasinya (SENAMIKA)*, hlmn. 92–101, 2022.

[22] V. Kotu dan B. Deshpande, “Chapter 12 - time series forecasting”, di dalam *Data Science (Second Edition)*, V. Kotu dan B. Deshpande, timed., Second Edition, Morgan Kaufmann, 2019, hlmn. 395–445. sumber: https : / / www . sciencedirect . com / science / article / pii / B9780128147610000125.

[23] U. Azmi, Z. N. Hadi, dan S. Soraya, “ARDL METHOD: Forecasting Data Curah Hujan Harian NTB”, *Jurnal Varian*, vol. 3, no. 2, hlmn. 73–82, 2020.

[24] R. T. R. Abadi, “Penerapan metode long short term memory dalam memprediksi jumlah kasus covid-19”, Universitas Islam Negeri Maulana Malik Ibrahim, 2021, hlmn. 16. sumber: http://etheses.uin-malang.ac.id/id/eprint/32662.

[25] A. krisma, M. Azhari, dan P. P. Widagdo, “Perbandingan metode double exponential smoothing dan triple exponential smoothing dalam parameter tingkat error mean absolute percentage error (mape) dan means absolute deviation (mad)”, 2019. sumber: https : / / api . semanticscholar . org / CorpusID:213911629.

[26] S. A. Wulandari, “Fluktuasi harga cabai merah di masa pandemi covid 19 di kota jambi”, en, *Jurnal MeA (Media Agribisnis)*, vol. 5, no. 2, hlmn. 112–120, Okt. 2020. sumber: http://mea.unbari.ac.id/index.php/MEA/article/view/82.

[27] D. Nauly, “Fluktuasi dan disparitas harga cabai di indonesia”, Jan. 2017.

[28] B. A. Aprian, Y. Azhar, dan V. R. S. Nastiti, "Prediksi Pendapatan Kargo Menggunakan Arsitektur Long Short Term Memory", *Jurnal Komputer Terapan*, vol. 6, no. 2, hlmn. 148–157, 2020.

[29] T. Deng, "Effect of the Number of Hidden Layer Neurons on the Accuracy of the Back Propagation Neural Network", vol. 74, hlmn. 462–468, 2023.

[30] N. Rochmawati, H. B. Hidayati, Y. Yamasari, H. P. A. Tjahyaningtijas, W. Yustanti, dan A. Prihanto, "Analisa Learning Rate dan Batch Size pada Klasifikasi Covid Menggunakan Deep Learning dengan Optimizer Adam", *Journal of Information Engineering and Educational Technology*, vol. 5, no. 2, hlmn. 44–48, 2021.

[31] G. Budiprasetyo, M. Hani'ah, dan D. Z. Aflah, "Prediksi Harga Saham Syariah Menggunakan Algoritma Long Short-Term Memory (LSTM)", *Jurnal Nasional Teknologi dan Sistem Informasi*, vol. 8, no. 3, hlmn. 164–172, 2023.

[32] M. Royun Nuha, T. Andita Putri, dan A. Dwi Utami, "Pendapatan Usahatani Cabai Merah Berdasarkan Musim di Provinsi Jawa Tengah", *Jurnal Ilmu Pertanian Indonesia*, vol. 28, no. 2, hlmn. 323–334, 2023.

[33] S. F. Handayani, R. W. Pratiwi, D. Dairoh, dan D. I. Af'idah, "Analisis Sentimen pada Data Ulasan Twitter dengan Long-Short Term Memory", *JTERA (Jurnal Teknologi Rekayasa)*, vol. 7, no. 1, hlmn. 39, 2022.

[34] R. P. Wibowo, N. Jessica, dan R. Surbakti, "Faktor-Faktor yang Mempengaruhi Permintaan dan Penawaran Bawang Merah di Indonesia Factors Influencing Demand and Supply of Shallots in Indonesia", vol. 6, no. 2, hlmn. 326–336, 2023.

LAMPIRAN

LAMPIRAN A

Perhitungan

A.1 Total Hasil Produksi dalam Satuan Provinsi

Tabel A.1 Data Produksi Kabupaten/Kota di Provinsi Lampung (2018–2023)

Kabupaten	**2019**		**...**	**2023**
	Januari	**Februari**		**Desember**
Kab. Lampung Barat	1990,00	1730,00	...	2679,00
Kab. Tanggamus	154,00	181,00	...	45,00
Kab. Lampung Selatan	10200,00	4100,00	...	1010,00
Kab. Lampung Timur	1435,00	872,00	...	173,50
Kab. Lampung Tengah	426,00	1553,00	...	657,00
Kab. Lampung Utara	420,00	590,00	...	24,00
Kab. Way Kanan	34,00	28,00	...	218,00
Kab. Tulang Bawang	104,00	141,00	...	22,00
Kab. Pesawaran	21200,00	4950,00	...	517,30
Kab. Pringsewu	216,00	00	...	105,00
Kab. Mesuji	1570,00	1570,00	...	630,00
Kab. Tulang Bawang Barat	491,00	87,00	...	234,00
Kab. Pesisir Barat	305,00	251,00	...	49,50
Bandar Lampung	00	4,00	...	0,00
Metro	255,00	00	...	10,00
Total Lampung	**46000,00**	**22157,00**	**...**	**6374,30**

A.2 Normalisasi Data (2.2)

Perhitungan normalisasi ini merujuk pada Subbab 2.2 menggunakan Persamaan 2.1.

	Harga	Produksi
Minimun	8000	5106,55
Maximum	70000	46000
x	13750	46000

$$x'_{\text{Harga}} = \frac{x - x_{\min}}{x_{\max} - x_{\min}} = \frac{13750 - 8000}{70000 - 8000} = \frac{5750}{62000}$$
$$= 0,0927$$

$$x'_{\text{Produksi}} = \frac{x - x_{\min}}{x_{\max} - x_{\min}} = \frac{46000 - 5106,55}{46000 - 5106,55} = \frac{40893,45}{40893,45}$$
$$= 1$$

Tabel A.2 Dataset Setelah Normalisasi

Harga	Produksi
0,0927	1,0000
0,1048	0,4169
0,0145	0,3911
0,0000	0,1329
0,0806	0,0854
0,1492	0,1565
0,3548	0,0421
0,9194	0,0312
0,9194	0,3050
0,2742	0,1377
0,3548	0,2953
0,1452	0,2761
0,1774	0,0464

Harga	Produksi
0,5645	0,0413
0,5645	0,4293
0,2782	0,1354
0,1089	0,1728
0,0040	0,4163
0,0040	0,1378
0,0363	0,0302
0,1129	0,1180
0,0927	0,0456
0,2460	0,0795
0,2460	0,2431
0,6452	0,5028
0,8629	0,1160
0,4274	0,1649
0,4274	0,2052
0,2298	0,1357
0,1210	0,1742
0,1210	0,2209
0,1210	0,2193
0,0968	0,1908
0,0927	0,1578
0,0927	0,4913
0,2863	0,1378
0,9194	0,2288
0,2016	0,1050
0,2016	0,1527
0,4476	0,1144
0,2742	0,1612
0,3871	0,1638
0,7581	0,0698

Harga	Produksi
1,0000	0,1439
0,6129	0,1905
0,4597	0,0818
0,2903	0,1968
0,2742	0,2873
0,2258	0,1094
0,2742	0,1351
0,2661	0,2608
0,2742	0,1361
0,1613	0,1305
0,2742	0,0679
0,2097	0,0378
0,1935	0,1711
0,3226	0,0614
0,2258	0,0956
0,3226	0,0000
0,8992	0,0310

A.3 LSTM (2.3)

Selanjutnya, perhitungan LSTM ini merujuk pada Subbab 2.3 dengan menggunakan Persamaan 2.5 sampai 2.10

1. **Forget Gate**
   Diketahui :
   $W_f =$

$$\begin{bmatrix} 0,327 & 0,411 & 0,281 & 0,277 \\ 0,119 & 0,037 & 0,469 & 0,522 \end{bmatrix}$$

$b_f =$

$$\begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$h_{t-1}, X_t =$

$$\begin{bmatrix} 0 \\ 0 \\ 0,0927 \\ 0,1 \end{bmatrix}$$

Rumus *Forget gate* :

$$f_t = \sigma(W_f[h_{t-1}, X_t] + b_f)$$

$$f_t = \sigma\left(\begin{bmatrix} 0,327 & 0,411 & 0,281 & 0,277 \\ 0,119 & 0,037 & 0,469 & 0,522 \end{bmatrix}\begin{bmatrix} 0 \\ 0 \\ 0,0927 \\ 1 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \end{bmatrix}\right)$$

$$f_t = \sigma\left(\begin{bmatrix} 0,327 \cdot 0 + 0,411 \cdot 0 + 0,281 \cdot 0,0927 + 0,277 \cdot 1 \\ 0,119 \cdot 0 + 0,037 \cdot 0 + 0,469 \cdot 0,0927 + 0,522 \cdot 1 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \end{bmatrix}\right)$$

$$f_t = \sigma\left(\begin{bmatrix} 0,0261 + 0,277 \\ 0,0435 + 0,522 \end{bmatrix}\right)$$

$$f_t = \sigma\left(\begin{bmatrix} 0,3031 \\ 0,5655 \end{bmatrix}\right)$$

$$f_t = \begin{bmatrix} 0,5757 \\ 0,6377 \end{bmatrix}$$

2. **Input Gate**

Diketahui :

$W_i =$

$$\begin{bmatrix} 0,236 & 0,540 & 0,556 & 0,181 \\ 0,463 & 0,159 & 0,370 & 0,017 \end{bmatrix}$$

$b_i =$

$$\begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$h_{t-1}, X_t =$

$$\begin{bmatrix} 0 \\ 0 \\ 0,0927 \\ 1 \end{bmatrix}$$

Rumus *Input gate* :

$$i_t = \sigma(W_i[h_{t-1}, X_t] + b_i)$$

$$i_t = \sigma\left(\begin{bmatrix} 0,236 & 0,540 & 0,556 & 0,181 \\ 0,463 & 0,159 & 0,370 & 0,017 \end{bmatrix}\begin{bmatrix} 0 \\ 0 \\ 0,0927 \\ 1 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \end{bmatrix}\right)$$

$$i_t = \sigma\left(\begin{bmatrix} 0,236 \cdot 0 + 0,540 \cdot 0 + 0,556 \cdot 0,0927 + 0,181 \cdot 1 \\ 0,463 \cdot 0 + 0,159 \cdot 0 + 0,370 \cdot 0,0927 + 0,017 \cdot 0 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \end{bmatrix}\right)$$

$$i_t = \sigma\left(\begin{bmatrix} 0,0515 + 0,181 \\ 0,0343 + 0,017 \end{bmatrix}\right)$$

$$i_t = \sigma\left(\begin{bmatrix} 0,2325 \\ 0,0513 \end{bmatrix}\right)$$

$$i_t = \begin{bmatrix} 0,5577 \\ 0,5128 \end{bmatrix}$$

3. **Kandidat *Cell state***

Diketahui :

$W_c =$

$$\begin{bmatrix} 0,477 & 0,128 & 0,555 & 0,012 \\ 0,161 & 0,212 & 0,551 & 0,381 \end{bmatrix}$$

$b_c =$

$$\begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$h_{t-1}, X_t =$

$$\begin{bmatrix} 0 \\ 0 \\ 0,0927 \\ 1 \end{bmatrix}$$

Rumus *Input gate* :

$$\hat{C}_t = \tanh((Wc[h_{t-1}, X_t] + b_c)$$

$$\hat{C}_t = \tanh\left(\begin{bmatrix} 0,477 & 0,128 & 0,555 & 0,012 \\ 0,161 & 0,212 & 0,551 & 0,381 \end{bmatrix}\begin{bmatrix} 0 \\ 0 \\ 0,0927 \\ 1 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \end{bmatrix}\right)$$

$$\hat{C}_t = \tanh\left(\begin{bmatrix} 0,477 \cdot 0 + 0,128 \cdot 0 + 0,555 \cdot 0,0927 + 0,012 \cdot 1 \\ 0,161 \cdot 0 + 0,212 \cdot 0 + 0,551 \cdot 0,0927 + 0,381 \cdot 1 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \end{bmatrix}\right)$$

$$\hat{C}_t = \tanh\left(\begin{bmatrix} 0,0514 + 0,012 \\ 0,0511 + 0,381 \end{bmatrix}\right)$$

$$\hat{C}_t = \tanh\left(\begin{bmatrix} 0,0634 \\ 0,4321 \end{bmatrix}\right)$$

$$\hat{C}_t = \begin{bmatrix} 0,0632 \\ 0,4052 \end{bmatrix}$$

4. **Cell State**

   Diketahui :

   $C_{t-1} =$

$$\begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

   Rumus *Cell state* :

$$C_t = f_t \cdot C_{t-1} + i_t \cdot \hat{C}_t$$

$$C_t = \begin{bmatrix} 0,5757 \\ 0,6377 \end{bmatrix}\begin{bmatrix} 0 \\ 0 \end{bmatrix} + \begin{bmatrix} 0,5577 \\ 0,5128 \end{bmatrix}\begin{bmatrix} 0,0632 \\ 0,4052 \end{bmatrix}$$

$$C_t = \begin{bmatrix} 0,5577 \cdot 0,0632 \\ 0,5128 \cdot 0,4052 \end{bmatrix}$$

$$C_t = \begin{bmatrix} 0,0353 \\ 0,2073 \end{bmatrix}$$

5. **Output Gate**

Diketahui :

$W_o =$

$$\begin{bmatrix} 0,311 & 0,352 & 0,091 & 0,540 \\ 0,061 & 0,191 & 0,144 & 0,207 \end{bmatrix}$$

$b_o =$

$$\begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$h_{t-1}, X_t =$

$$\begin{bmatrix} 0 \\ 0 \\ 0,25 \\ 0,3283 \end{bmatrix}$$

Rumus *Output gate*

$$o_t = \sigma(W_o[h_{t-1}, X_t] + b_o)$$

$$o_t = \sigma\left(\begin{bmatrix} 0,311 & 0,352 & 0,091 & 0,540 \\ 0,061 & 0,191 & 0,144 & 0,207 \end{bmatrix}\begin{bmatrix} 0 \\ 0 \\ 0,0927 \\ 1 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \end{bmatrix}\right)$$

$$o_t = \sigma\left(\begin{bmatrix} 0,311 \cdot 0 + 0,352 \cdot 0 + 0,091 \cdot 0,0927 + 0,540 \cdot 1 \\ 0,061 \cdot 0 + 0,191 \cdot 0 + 0,144 \cdot 0,0927 + 0,207 \cdot 1 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \end{bmatrix}\right)$$

$$o_t = \sigma\left(\begin{bmatrix} 0,0084 + 0,540 \\ 0,0133 + 0,207 \end{bmatrix}\right)$$

$$o_t = \sigma\left(\begin{bmatrix}0,5484\\0,2203\end{bmatrix}\right)$$

$$o_t = \begin{bmatrix}0,6337\\0,5549\end{bmatrix}$$

Rumus *hidden state* :

$$h_t = o_t \cdot \tanh(C_t)$$

$$h_t = \begin{bmatrix}0,6337\\0,5549\end{bmatrix} \cdot tanh\begin{bmatrix}0,0353\\0,2073\end{bmatrix}$$

$$h_t = \begin{bmatrix}0,6337\\0,5549\end{bmatrix} \cdot \begin{bmatrix}0,0353\\0,2059\end{bmatrix}$$

$$h_t = \begin{bmatrix}0,0224\\0,1143\end{bmatrix}$$

A.4 Perhitungan Manual Total Parameter Model LSTM

Pada lampiran ini, dilakukan perhitungan manual jumlah parameter untuk model LSTM yang digunakan dalam penelitian ini. Perhitungan ini dilakukan dengan menggunakan rumus berikut:

$$\text{Total parameter} = 4 \times (h \times (h + x) + h)$$

Keterangan:

- h : jumlah unit dalam lapisan LSTM.
- x : jumlah fitur input pada lapisan LSTM.

```
Model: "sequential"
_________________________________________________________
 Layer (type)      Output Shape          Param #
```

```
=================================================
 lstm_1 (LSTM)     (None, 6, 32)        4480
 lstm_2 (LSTM)     (None, 32)           8320
 dense (Dense)     (None, 2)            66
=================================================
Total params: 12866 (50.26 KB)
Trainable params: 12866 (50.26 KB)
Non-trainable params: 0 (0.00 Byte)
```

Model terdiri dari dua lapisan LSTM dan satu lapisan Dense. Berikut adalah perhitungan parameter pada masing-masing lapisan:

1. LSTM Layer 1

Lapisan LSTM pertama memiliki:

- Jumlah unit (h) = 32
- Jumlah fitur input (x) = 2

$$\begin{aligned}\text{Total parameter} &= 4 \times (32 \times (32 + 2) + 32) \\ &= 4 \times 1120 \\ &= 4880 \text{ parameter}\end{aligned}$$

2. LSTM Layer 2

Lapisan LSTM kedua memiliki:

- Jumlah unit (h) = 32
- Jumlah fitur input dari lapisan sebelumnya (x) = 32

$$\begin{aligned}\text{Total parameter} &= 4 \times (32 \times (32 + 32) + 32) \\ &= 4 \times 2080 \\ &= 8320 \text{ parameter}\end{aligned}$$

4. Dense Layer

Lapisan Dense memiliki:

- Jumlah unit input = 32 (dari lapisan LSTM terakhir)
- Jumlah unit output = 2

$$\begin{aligned}\text{Total parameter} &= (32 \times 2) + 2 \\ &= 64 + 2 \\ &= 66 \text{ parameter}\end{aligned}$$

Total Parameter Model

Jumlah total parameter pada model dihitung dengan menjumlahkan parameter pada setiap lapisan sebagai berikut:

$$\begin{aligned}\text{Total parameter} &= 4480 + 8320 + 66 \\ &= 12866 \text{ parameter}\end{aligned}$$

A.5 Perhitungan Denormalisasi

Perhitungan normalisasi ini merujuk pada Subbab 2.2 menggunakan Persamaan 2.2.

	Harga	**Produksi**
Minimun	8000	5106,55
Maximum	70000	46000
x’	0,7634	0,0718

$$
\begin{aligned}
x_{\text{harga}} &= x'_{\text{harga}} \times (x_{\max} - x_{\min}) + x_{\min} \\
&= 0,7634 \times (70000 - 8000) + 8000 \\
&= 0,7634 \times 62000 + 8000 \\
&= 47330,8 + 8000 \\
&= 55330,8
\end{aligned}
$$

$$
\begin{aligned}
x_{\text{produksi}} &= x'_{\text{harga}} \times (x_{\max} - x_{\min}) + x_{\min} \\
&= 0,0718 \times (46000 - 5106,55) + 5106,55 \\
&= 0,0718 \times 40893,45 + 5106,55 \\
&= 2935,56 + 5106,55 \\
&= 8042,11
\end{aligned}
$$

A.6 Perhitungan MAE dan MAPE

Menghitung MAE dan MAPE menggunakan data uji pada tabel sebelumnya.

$$
\begin{aligned}
\text{MAE}_{\text{harga}} &= \frac{1}{N}\sum_{i=1}^{N}|y_i - \hat{y}_i| \\
&= \frac{1}{18}\left(|55000 - 54555,02| + |70000 - 68934,27| + \ldots\right. \\
&\quad \left.+|63750 - 64421,50|\right) \\
&= \frac{1}{18}\left(444,97 + 1065,72 + \cdots + 671,50\right) \\
&= 613,25
\end{aligned}
$$

$$
\begin{aligned}
\text{MAPE}_{\text{harga}} &= \frac{100\%}{N}\sum_{i=1}^{N}\frac{|y_i - \hat{y}_i|}{|y_i|} \\
&= \frac{100\%}{18}\left(\frac{|55000 - 54555,02|}{|55000|} + \frac{|70000 - 64421,50|}{|70000|} + \ldots\right. \\
&\quad \left.+\left(\frac{|63750,0 - 64651,54|}{|63750,0|}\right)\right) \\
&= \frac{100\%}{18}\left(0,8090 + 1,5225 + \cdots + 1,0533\right) \\
&= 2,11\%
\end{aligned}
$$

$$
\begin{aligned}
\text{MAE}_{\text{produksi}} &= \frac{1}{N}\sum_{i=1}^{N}|y_i - \hat{y}_i| \\
&= \frac{1}{18}\left(|7960{,}4 - 8298{,}15| + |10991{,}89 - 11010{,}28| + \ldots\right. \\
&\quad \left. + |6374{,}30 - 7087{,}86|\right) \\
&= \frac{1}{18}\left(337{,}75 + 18{,}39 + \cdots + 713{,}56\right) \\
&= 239{,}03
\end{aligned}
$$

$$
\begin{aligned}
\text{MAPE}_{\text{produksi}} &= \frac{100\%}{N}\sum_{i=1}^{N}\frac{|y_i - \hat{y}_i|}{|y_i|} \\
&= \frac{100\%}{18}\left(\frac{|7960,4 - 8298,15|}{|7960,4|} + \frac{|10991,89 - 11010,28|}{|10991,89|} + \ldots\right. \\
&\quad \left. + \frac{|6374,30 - 7087,86|}{|6374,30|}\right) \\
&= \frac{100\%}{13}\left(4,243 + 0,167 + \cdots + 11,19\right) \\
&= 2,91\%
\end{aligned}
$$

Tabel A.3 Tabel Perbandingan Harga Aktual dan Prediksi

Tanggal	Harga	Prediksi	MAE	MAPE
01/07/2022	55000	54555,0273	444,9727	0,8090%
01/08/2022	70000	68934,2734	1065,7266	1,5225%
01/09/2022	46000	45272,8633	727,1367	1,5807%
03/10/2022	36500	36410,6328	89,3672	0,2448%
01/11/2022	26000	24978,4805	1021,5195	3,9289%
01/12/2022	25000	23765,4238	1234,5762	4,9383%
02/01/2023	22000	21169,6152	830,3848	3,7745%
01/02/2023	25000	25118,7715	118,7715	0,4751%
01/03/2023	24500	23102,4238	1397,5762	5,7044%
03/04/2023	25000	25053,1367	53,1367	0,2125%
01/05/2023	18000	17626,9785	373,0215	2,0723%
01/06/2023	25000	24175,5566	824,4434	3,2978%
03/07/2023	21000	20991,5078	8,4922	0,0404%
01/08/2023	20000	20295,3867	295,3867	1,4769%
01/09/2023	28000	26788,1484	1211,8516	4,3280%
02/10/2023	22000	22059,3223	59,3223	0,2696%
01/11/2023	28000	28611,4004	611,4004	2,1836%
01/12/2023	63750	64421,5039	671,5039	1,0533%
Rata-Rata			**613,25**	**2,11%**

Tabel A.4 Tabel Perbandingan Produksi Aktual dan Prediksi

Tanggal	Produksi	Prediksi	MAE	MAPE
01/07/2022	7960,4	8298,1572	337,7572	4,2430%
01/08/2022	10991,89	11010,2803	18,3903	0,1673%
01/09/2022	12897,16	12962,3086	65,1486	0,5051%
03/10/2022	8450,65	8528,0400	77,3900	0,9158%
01/11/2022	13153,7	13279,6748	125,9748	0,9577%
01/12/2022	16856,96	16713,6230	143,3370	0,8503%
02/01/2023	9582,2	9605,0244	22,8244	0,2382%
01/02/2023	10632,8	10631,8818	0,9182	0,0086%
01/03/2023	15771,6	15474,2471	297,3529	1,8854%
03/04/2023	10672,4	10804,8115	132,4115	1,2407%
01/05/2023	10442,95	10313,9727	128,9773	1,2351%
01/06/2023	7883,05	8039,2710	156,2210	1,9817%
03/07/2023	6651,5	6742,4668	90,9668	1,3676%
01/08/2023	12104,65	11309,6289	795,0211	6,5679%
01/09/2023	7617,3	7406,3276	210,9724	2,7696%
02/10/2023	9016,75	9378,9102	362,1602	4,0165%
01/11/2023	5106,55	5729,7231	623,1731	12,2034%
01/12/2023	6374,3	7087,8652	713,5652	11,1944%
Rata-Rata			**239,03**	**2,91%**

LAMPIRAN B

Tabel Evaluasi Model

B.1 1 *Hidden Layer* LSTM

Tabel B.1 Hasil Evaluasi Data Latih 1 *Hidden Layer* LSTM

Model	***Neuron***	***Batch Size***	***Loss***	**MAE**		**MAPE (%)**	
				Harga	**Produksi**	**Harga**	**Produksi**
1	2	1	0,0263	9343,85	3983,92	42,4%	31,66%
2	2	2	0,0266	9665,64	4017,90	46,5%	32,88%
3	2	4	0,0326	10056,01	3940,52	46,84%	30,67%
4	2	8	0,0310	9568,73	3983,04	43,06%	31,28%
5	2	16	0,0336	11103,31	4408,78	53,59%	31,97%
6	4	1	0,0142	5939,65	3355,65	30,46%	25,84%
7	4	2	0,0304	9673,08	3754,77	44,25%	30,29%
8	4	4	0,0274	10150,75	3935,69	47,90%	30,42%
9	4	8	0,0286	9545,80	3784,86	43,92%	29,16%
10	4	16	0,0296	97794,80	3988,12	43,09%	30,20%
11	8	1	0,0104	4624,44	3230,42	24,92%	24,99%
12	8	2	0,0153	5602,71	3334,59	29,23%	28,15%
13	8	4	0,0270	8720,62	3911,90	40,28%	32,04%
14	8	8	0,0269	8842,19	3782,93	40,24%	29,54%
15	8	16	0,0286	9368,53	4060,56	41,48%	31,15%
16	16	1	0,0027	2113,21	1866,12	10,55%	14,92%
17	16	2	0,0063	3130,23	2777,28	15,99%	21,18%
18	16	4	0,0172	6565,55	3414,96	31,36%	27,80%
19	16	8	0,0209	7301,11	3638,23	31,02%	28,67%
20	16	16	0,0208	7681,21	4033,21	32,93%	31,35%
21	**32**	**1**	**0,0011**	**1179,59**	**1256,21**	**5,52%**	**10,96%**
22	32	2	0,0022	1115,25	1646,14	5,36%	15,49%
23	32	4	0,0048	3673,71	2529,00	17,22%	22,82%
24	32	8	0,0161	6479,87	3654,15	27,34%	29,63%
25	32	16	0,0101	4005,36	3018,16	19,51%	24,68%

Tabel B.2 Hasil Evaluasi Data Uji 1 *Hidden Layer* LSTM

Model	***Neuron***	***Batch Size***	**MAE**		**MAPE**	
			Harga	**Produksi**	**Harga**	**Produksi**
1	2	1	8454,42	2976,03	27,36%	36,19%
2	2	2	8659,35	3181,26	27,90%	38,84%
3	2	4	8611,85	2788,99	26,77%	33,84%
4	2	8	7981,66	2989,57	22,71%	36,65%
5	2	16	8488,51	3179,17	24,43%	37,05%
6	4	1	8149,24	2785,11	25,97%	33,61%
7	4	2	8053,65	2945,33	24,08%	36,39%
8	4	4	9272,09	2730,63	31,28%	33,21%
9	4	8	7823,94	3157,80	22,79%	40,01%
10	4	16	7964,61	2377,57	23,58%	27,80%
11	8	1	7817,69	2786,72	25,72%	33,80%
12	8	2	8178,37	2488,02	25,20%	29,54%
13	8	4	8297,12	2384,39	26,03%	28,01%
14	8	8	7864,97	2961,16	24,17%	36,49%
15	8	16	7946,64	2453,53	23,86%	28,11%
16	16	1	4687,45	2189,39	17,03%	23,58%
17	16	2	6380,70	2585,13	21,15%	30,34%
18	16	4	8094,32	2035,52	26,42%	22,60%
19	16	8	7836,72	2598,50	24,75%	31,71%
20	16	16	8083,08	2113,44	26,23%	24,98%
21	**32**	**1**	**1875,84**	**765,19**	**5,94%**	**8,44%**
22	32	2	2819,16	1222,97	10,09%	14,06%
23	32	4	5121,29	1646,22	17,52%	17,90%
24	32	8	6997,63	1812,98	23,28%	21,15%
25	32	16	5704,38	1793,08	18,66%	20,44%

B.2 2 *Hidden Layer* LSTM

Tabel B.3 Hasil Evaluasi Data Latih 1 *Hidden Layer* LSTM

Model	***Neuron***	***Batch Size***	***Loss***	**MAE**		**MAPE (%)**	
				Harga	**Produksi**	**Harga**	**Produksi**
26	2	1	0,0203	7271,26	3891,41	36,16%	31,50%
27	2	2	0,0165	5505,44	3971,64	28,13%	31,71%
28	2	4	0,0225	10589,74	3937,78	52,59%	30,99%
29	2	8	0,0425	12918,30	3932,55	67,93%	31,22%
30	2	16	0,0299	9181,40	4197,50	41,65%	32,97%
31	4	1	0,0074	2838,73	3432,01	16,43%	27,36%
32	4	2	0,0198	6962,25	3351,42	35,78%	27,55%
33	4	4	0,0369	10747,87	3697,27	52,69%	30,00%
34	4	8	0,0357	11136,32	3753,04	55,26%	30,29%
35	4	16	0,0384	12058,65	3863,51	60,18%	28,58%
36	8	1	0,0036	1957,68	2109,89	9,46%	17,98%
37	8	2	0,0115	5100,49	3318,91	24,67%	28,58%
38	8	4	0,0244	8125,07	3829,08	34,17%	30,28%
39	8	8	0,0209	7177,19	3753,02	30,60%	31,42%
40	8	16	0,0273	8862,16	3854,07	36,97%	29,04%
41	16	1	0,0011	1362,25	926,78	6,50%	8,25%
42	16	2	0,0031	1982,16	1872,66	11,64%	17,82%
43	16	4	0,0055	3282,37	2559,15	16,51%	22,13%
44	16	8	0,0108	4414,86	3347,04	21,67%	28,12%
45	16	16	0,0127	4928,70	3404,83	20,78%	28,31%
46	**32**	**1**	**3,887e-4**	**1660,93**	**554,77**	**9.17%**	**4.77%**
47	32	2	0,0023	2645,35	1377,21	12,18%	12,89%
48	32	4	0,0011	1441,69	888,19	7,88%	7,56%
49	32	8	0,0057	3728,23	2162,18	18,73%	19,07%
50	32	16	0,0062	2560,05	2411,32	13,92%	20,34%

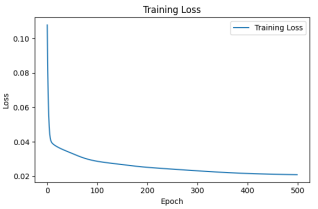
Tabel B.4 Hasil Evaluasi Data Uji 2 *Hidden Layer* LSTM

Model	***Neuron***	***Batch***	**MAE**		**MAPE**	
		Size	**Harga**	**Produksi**	**Harga**	**Produksi**
26	2	1	8052,95	3019,92	24,92%	37,21%
27	2	2	8670,99	2984,80	25,56%	36,81%
28	2	4	9410,05	2859,39	28,48%	34,76%
29	2	8	10544,47	2952,35	29,19%	36,15%
30	2	16	8301,48	2763,53	24,71%	31,97%
31	4	1	4371,69	2747,47	15,68%	31,26%
32	4	2	8116,72	2478,83	24,41%	28,58%
33	4	4	8549,09	2262,07	24,08%	26,34%
34	4	8	9619,85	2604,69	25,99%	32,04%
35	4	16	9669,52	2548,30	26,41%	31,13%
36	8	1	2361,31	1857,17	8,22%	21,32%
37	8	2	7729,54	2099,58	25,34%	23,74%
38	8	4	6883,85	2344,95	24,50%	28,20%
39	8	8	7658,59	2386,19	25,00%	27,26%
40	8	16	8044,62	2549,44	24,57%	28,68%
41	16	1	1529,40	1091,10	5,28%	11,55%
42	16	2	3040,85	1379,32	10,94%	15,54%
43	16	4	4711,07	1877,26	15,99%	20,96%
44	16	8	7011,40	2264,76	22,63%	25,63%
45	16	16	5489,63	1784,95	19,08%	20,07%
46	**32**	**1**	**613,25**	**239,03**	**2,11%**	**2,91%**
47	32	2	2243,87	909,92	8,40%	9,87%
48	32	4	2523,06	1284,21	9,17%	13,07%
49	32	8	5572,22	1858,79	20,28%	20,50%
50	32	16	5112,22	1717,14	15,90%	18,69%

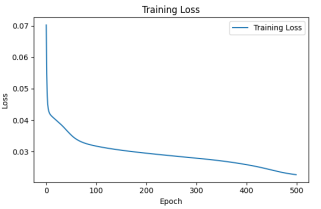
LAMPIRAN C

Gambar Evaluasi Model

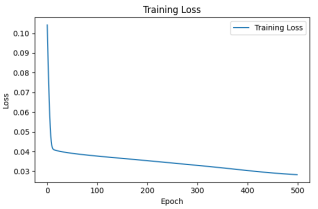
C.1 Gambar *Loss Training* 1 *Hidden Layer* LSTM



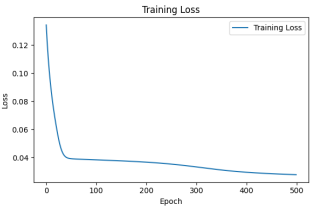
(a) Model 1



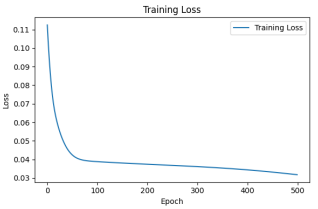
(b) Model 2



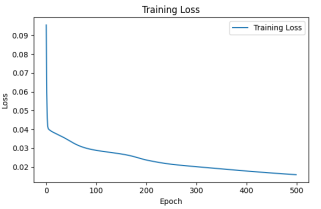
(c) Model 3



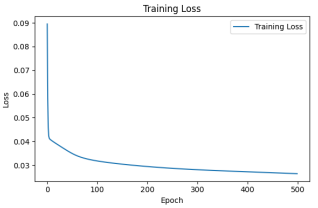
(d) Model 4



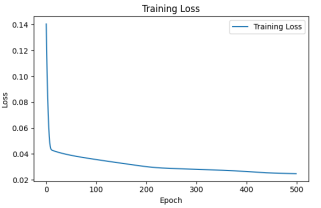
(e) Model 5



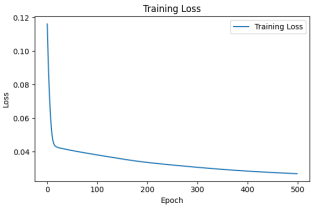
(f) Model 6



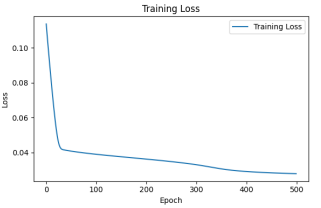
(g) Model 7



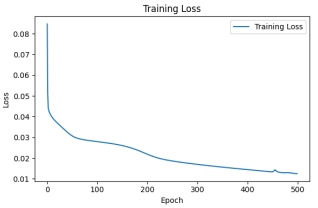
(h) Model 8



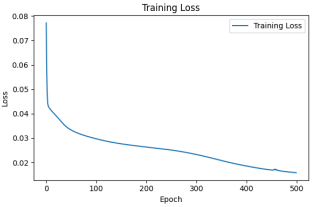
(a) Model 9



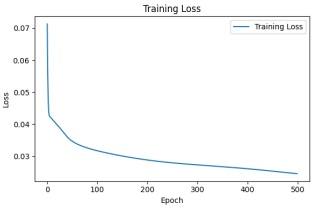
(b) Model 10



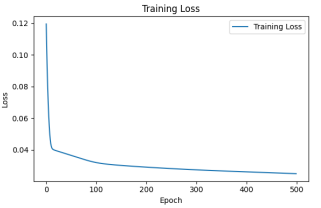
(c) Model 11



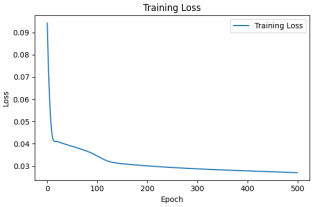
(d) Model 12



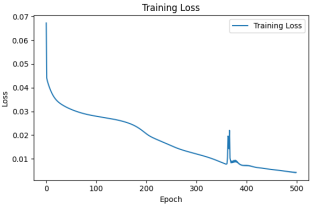
(e) Model 13



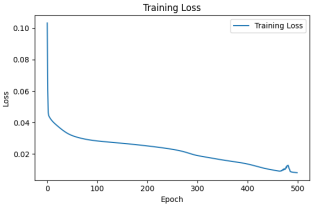
(f) Model 14



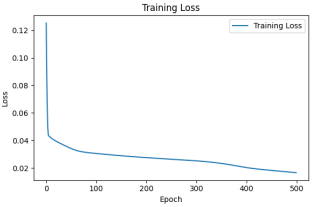
(g) Model 15



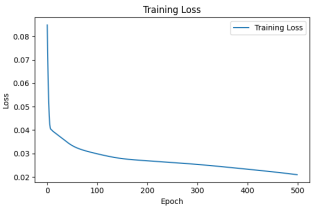
(h) Model 16



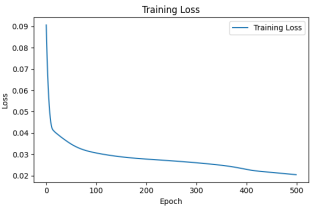
(i) Model 17



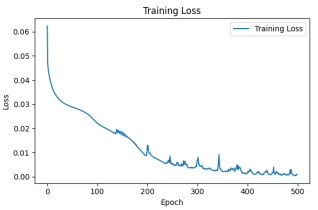
(j) Model 18



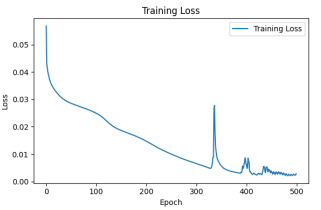
(a) Model 19



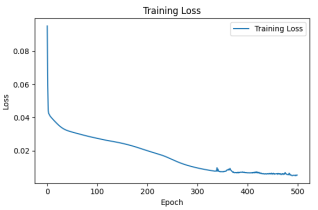
(b) Model 20



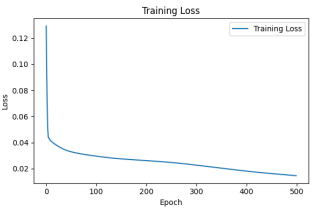
(c) Model 21



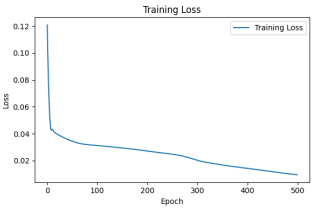
(d) Model 22



(e) Model 23

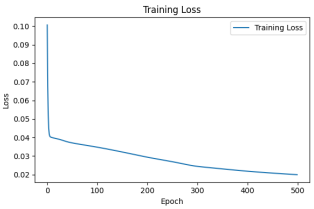


(f) Model 24

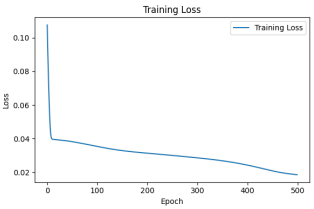


(g) Model 25

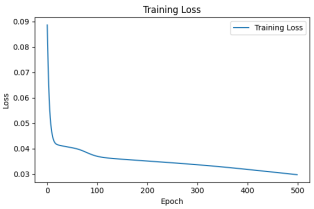
C.2 Gambar *Loss Training* 2 *Hidden Layer* LSTM



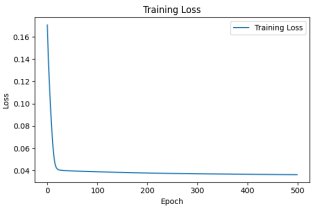
(a) Model 26



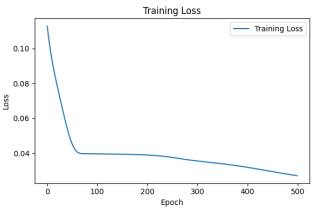
(b) Model 27



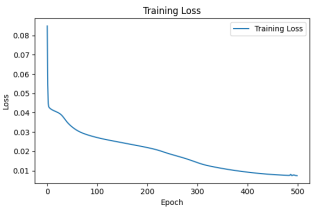
(c) Model 28



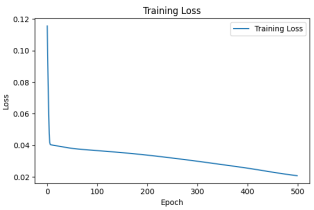
(d) Model 29



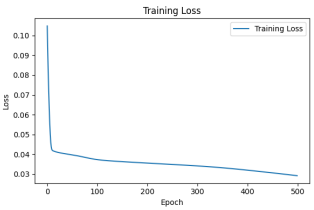
(e) Model 30



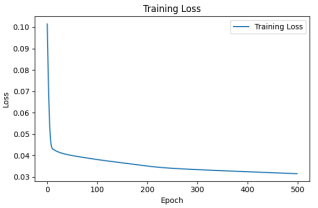
(f) Model 31



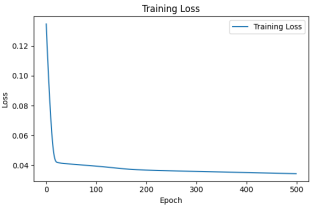
(g) Model 32



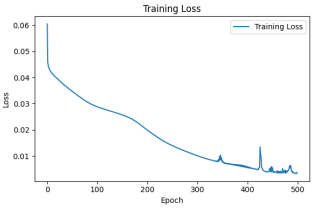
(h) Model 33



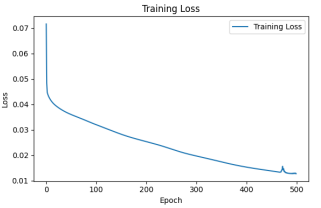
(a) Model 34



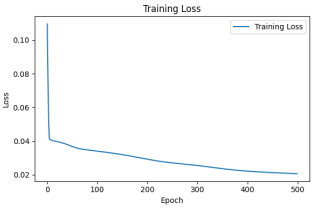
(b) Model 35



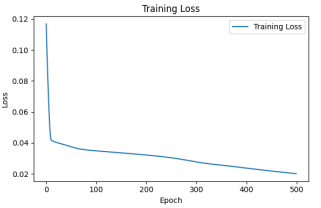
(c) Model 36



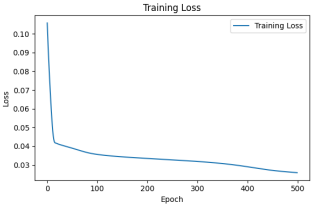
(d) Model 37



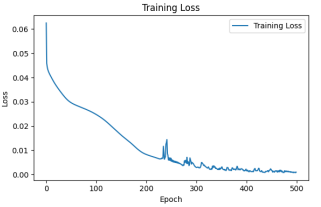
(e) Model 38



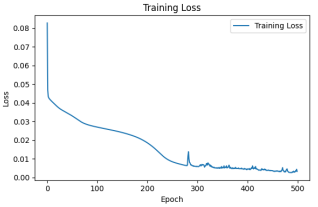
(f) Model 39



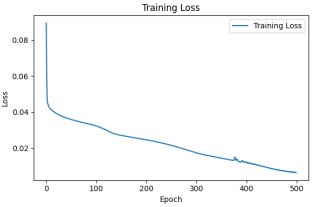
(g) Model 40



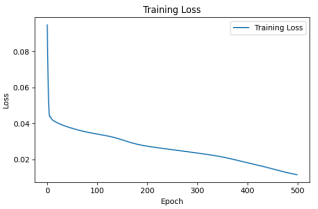
(h) Model 41



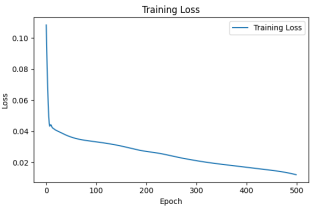
(i) Model 42



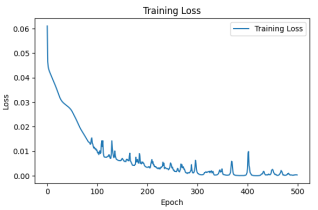
(j) Model 43



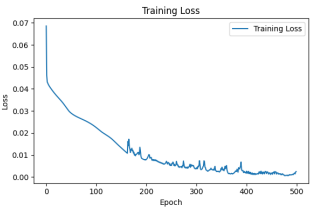
(a) Model 44



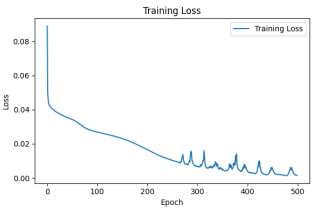
(b) Model 45



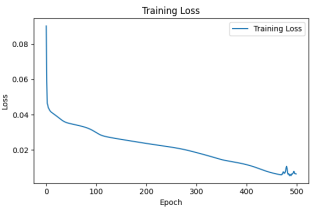
(c) Model 46



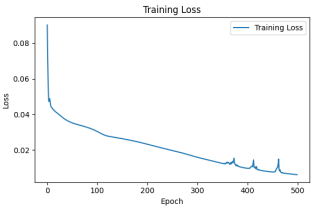
(d) Model 47



(e) Model 48



(f) Model 49



(g) Model 50